



浙江大学

ZHEJIANG UNIVERSITY

校园行为识别系统
系统设计文档

大华杯项目设计文档

2026 年 8 月 31 日

目录

第 1 章 文档概述	1
1.1 编写目的	1
1.2 项目背景	1
1.3 项目目标	1
第 2 章 系统需求分析	2
2.1 功能需求	2
2.1.1 时空特征提取	2
2.1.2 时空图构建	2
2.1.3 语义映射	2
2.1.4 大模型推理	2
2.1.5 伪标签筛选	2
2.1.6 知识蒸馏	3
2.1.7 增量学习	3
2.1.8 可视化展示	3
2.2 非功能需求	3
2.2.1 可解释性	3
2.2.2 可进化性	3
2.2.3 轻量化	4
2.2.4 鲁棒性	4
2.2.5 隐私保护	4
2.2.6 代码规范	4
第 3 章 系统总体设计	5
3.1 总体架构图	5
3.2 系统模块划分	5
第 4 章 数据处理与骨架特征构建	7

4.1	数据输入	7
4.2	视频帧处理	8
4.2.1	帧采样	8
4.2.2	图像预处理	9
4.3	人体检测与多人姿态估计	9
4.3.1	RTMDet-S 人体检测	9
4.3.2	RTMPose-S 姿态估计	10
4.3.3	COCO17 骨架关键点	11
4.4	人体关联与跟踪	12
4.4.1	IoU 匹配	12
4.4.2	中心距离	12
4.4.3	短时遮挡处理	13
4.4.4	双人轨迹选择	14
4.5	坐标归一化	14
4.6	时序质量控制与关键点处理	15
4.6.1	关键点置信度过滤	15
4.6.2	人体缺失处理	15
4.6.3	时序平滑与插值	16
4.7	输出格式	16
第 5 章	语义增强的轻量级骨架行为识别模型设计	18
5.1	模型训练总体思路	18
5.2	阶段一：基于 Kinetics-400 的骨架动作预训练	19
5.2.1	骨架输入与时空图构建	19
5.3	ProtoGCN 主干：从关节运动到细粒度拓扑特征	20
5.3.1	GCN Block 与多尺度时间建模	20
5.4	MTE：增强样本相关的细粒度运动拓扑	21
5.5	PRN：基于运动原型重构高层关节关系	22
5.6	CSCL：增强原型重构结果的类别判别能力	23
5.7	阶段一训练结果：获得通用人体动作先验	24
5.8	阶段二：Campus6 六分类全参数微调	25
5.9	GAP：利用动作自然语言描述辅助 Campus6 微调	25

5.9.1 Campus6 身体部位级动作语义 Prompt 27

5.10 文本描述的语义编码 28

5.11 身体部位骨架特征提取 29

5.12 骨架—文本语义对齐 29

5.13 GAP 身体部位语义损失 31

5.14 Campus6 微调阶段联合损失 31

第 6 章 大模型语义理解设计33

6.1 多源输入 34

6.1.1 结构化语义信息 34

6.1.2 骨架视频流 34

6.1.3 学生模型 Top-KK 预测 35

6.2 提示词构建 36

6.2.1 教师角色定义 36

6.2.2 六分类类别约束 37

6.2.3 学生预测使用约束 37

6.2.4 事实约束与幻觉抑制 38

6.2.5 当前 Prompt 模板 39

6.3 大模型推理 40

6.3.1 结构化交互语义理解 40

6.3.2 骨架运动时序理解 41

6.3.3 学生预测参考与语义修正 41

6.4 结构化输出 42

6.4.1 伪标签 42

6.4.2 类别概率分布 43

6.4.3 置信度 43

6.4.4 语义解释 44

第 7 章 大小模型协同决策机制46

7.1 协同架构 46

7.2 大模型触发策略 46

7.2.1 预测置信度较低 47

7.2.2	Top-1 与 Top-2 过于接近	47
7.2.3	姿态数据质量较差	47
7.2.4	预测结果不稳定	48
7.3	学生模型与教师模型结果融合	48
7.4	冲突、异常与人工审核机制	49
7.4.1	模型高置信冲突	49
7.4.2	教师模型异常	50
7.4.3	输入数据异常	50
7.4.4	人工审核触发	50
第 8 章	模型压缩与知识蒸馏	52
8.1	设计目标	52
8.2	模型压缩方案选择	52
8.3	INT8 量化设计	53
8.4	Logits 知识蒸馏设计	54
8.5	蒸馏损失设计	54
8.6	QAT 与知识蒸馏联合训练	55
第 9 章	增量学习机制	57
9.1	增量学习总体设计	57
9.2	难例挖掘与高价值样本发现	58
9.3	增量数据集构建与采样策略	58
9.4	基于 LoRA 的增量微调	59
9.5	增量训练触发与任务调度	60
9.6	模型评估、更新与回滚	60
第 10 章	Web 可视化与交互演示	61
10.1	系统首页 / 总览页:	61
10.2	行为识别结果页:	61
10.3	大模型伪标签和人工审核页	61
10.4	增量学习和模型迭代页	61
10.5	模型管理页	61

10.6 系统设置页	61
第 11 章 项目代码结构与关键接口	64
第 12 章 预训练与微调数据集	65
第 14 章 项目完成情况	66
14.1 功能模块完成情况	66
14.2 综合技术要求完成情况	69
14.3 项目整体完成度总结	71
参考资料	72

第 1 章 文档概述

1.1 编写目的

本文档用于描述系统的总体架构、功能模块、核心算法、数据流程、接口设计及部署方案，为系统开发、测试和验收提供依据。

1.2 项目背景

随着智慧校园建设不断推进，校园公共区域的视频行为分析逐渐成为安全管理的重要手段。现有算法多依赖速度、距离和轨迹等表层时空特征，对“嬉戏追逐”“冲突推搡”等相似行为的语义区分能力有限，容易产生误报。同时，传统模型面对新型行为时迭代成本较高。因此，本项目拟构建大小模型协同的校园行为语义理解框架，在提升识别准确性的同时兼顾模型轻量化与持续进化能力。

1.3 项目目标

1. 实现六类校园行为细粒度识别；
2. 提升嬉戏行为与冲突行为的区分能力；
3. 建立大小模型协同机制；
4. 建立数据—大模型—小模型自进化闭环；
5. 实现边缘端轻量化部署；
6. 保护隐私，不随意上传视频

第 2 章 系统需求分析

2.1 功能需求

根据赛题基本功能要求，系统应具备时空特征提取、时空图构建、语义映射、大模型推理、伪标签筛选、知识蒸馏、增量学习以及结果可视化等功能。

2.1.1 时空特征提取

系统应能够从输入的校园行为视频或结构化人体关键点数据中提取与行为识别相关的时空信息，包括人体关键点、运动轨迹、运动速度及人体交互状态等，为后续行为建模提供基础数据。

2.1.2 时空图构建

系统应能够根据人体关键点及其时间序列关系构建 Spatio-Temporal Graph，将人体关键点表示为图节点，并通过空间连接关系和时间关联关系构建图边，实现人体行为的结构化表示。

2.1.3 语义映射

系统应能够将骨架运动特征、模型预测结果及相关行为信息转换为大模型能够理解的结构化语义描述或文本 Prompt，为后续大模型行为推理提供输入。

2.1.4 大模型推理

系统应支持调用大模型对行为样本进行进一步语义分析，重点处理小模型难以准确区分的低置信度、高混淆行为。

大模型应能够根据输入的行为信息输出行为类别、预测置信度及对应的判断结果，并为后续伪标签生成和知识迁移提供依据。

2.1.5 伪标签筛选

系统应能够对大模型产生的预测结果进行质量筛选，根据预测置信度等指标选择可靠的高质量样本。

对于置信度不足、模型结果存在冲突或难以确定的样本，应进入人工复核队列，避免低质量伪标签直接参与模型训练。

2.1.6 知识蒸馏

系统应建立 Teacher-Student 知识迁移框架，将大模型产生的高质量行为判断知识迁移至轻量级行为识别模型。

知识蒸馏可采用预测分布、软标签等信息进行知识传递，使轻量模型逐步学习大模型对复杂行为的判断能力。

2.1.7 增量学习

系统应支持将新增数据、困难样本以及经过筛选的伪标签样本加入训练数据集，对轻量模型进行进一步训练和更新。

通过难例挖掘、数据注入及模型微调，使模型能够随着新数据的不断积累持续提升行为识别能力。

2.1.8 可视化展示

系统可提供行为识别结果的可视化界面，用于展示输入视频、人体骨架、预测类别、预测置信度及相关推理结果，方便用户查看系统识别过程及最终结果。

2.2 非功能需求

2.2.1 可解释性

系统应能够输出行为识别结果对应的推理依据，使用户能够了解系统进行行为判断的主要依据。

对于调用大模型分析的样本，应能够输出自然语言形式的语义判断依据；对于仅由轻量模型完成推理的样本，应保证其预测类别和置信度等信息可追溯。

2.2.2 可进化性

系统应设计完整的数据闭环机制，使新增数据和困难样本能够经过大模型分析、伪标签筛选和人工复核后重新进入训练流程。

通过知识蒸馏和增量学习不断更新轻量模型，实现系统随数据积累持续优化。

2.2.3 轻量化

系统应满足边缘部署要求，最终部署模型大小应不超过 50 MB。

在保证行为识别性能的前提下，应通过轻量化模型设计及模型量化等方式降低模型存储空间和计算开销。

2.2.4 鲁棒性

系统应对实际校园场景中的复杂环境具有一定适应能力，包括：

- 人体部分遮挡；
- 光照条件变化；
- 摄像机视角变化；
- 多人交互场景；
- 部分人体关键点缺失或检测误差。

2.2.5 隐私保护

系统设计应尽量减少对原始视频及人脸信息的依赖。

在行为识别阶段优先采用人体姿态及骨架数据作为模型输入，减少原始人脸和视频信息在后续处理、存储及传输过程中的暴露风险。

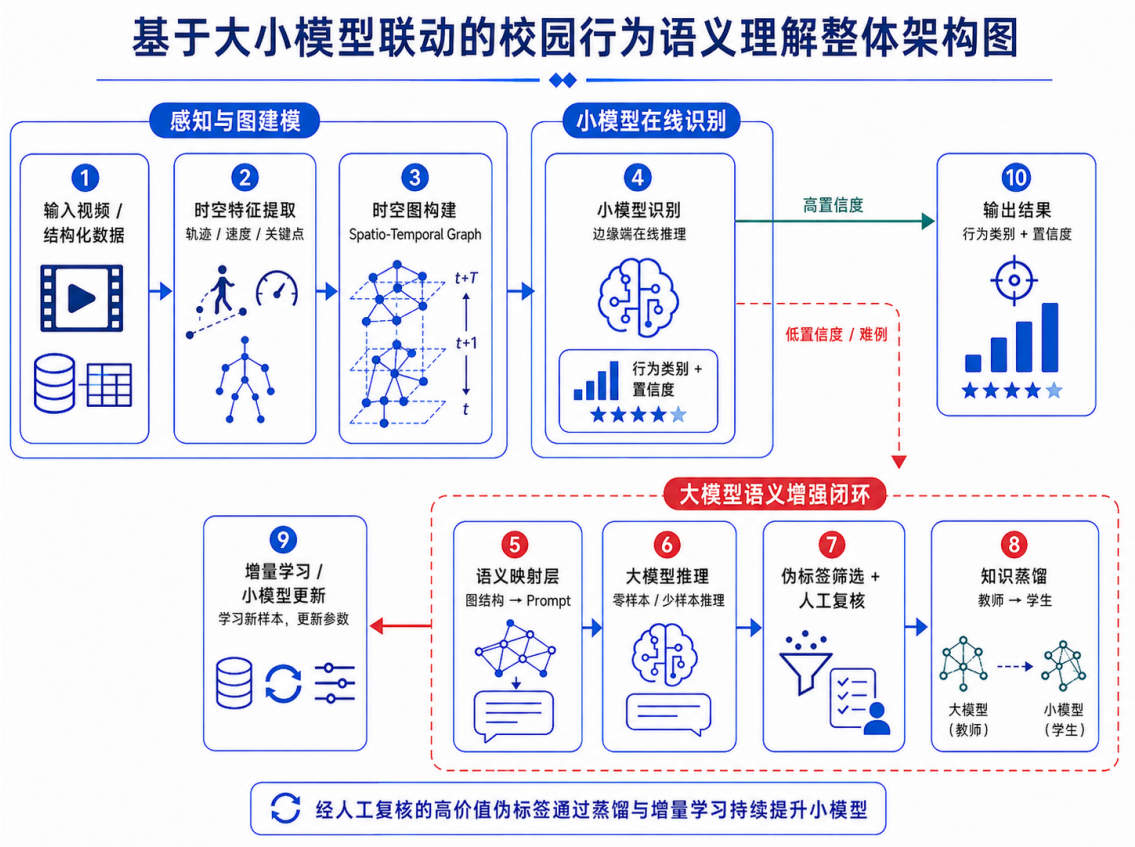
2.2.6 代码规范

系统代码应具有清晰的模块划分和目录结构，关键算法及核心流程应提供必要注释。

项目应提供 README 文档，说明环境配置、模型运行、训练测试及系统启动方式，保证系统具有良好的可维护性和可复现性。

第 3 章 系统总体设计

3.1 总体架构图



3.2 系统模块划分


模块	功能
数据输入模块	视频读取与预处理
骨架提取模块	多人关键点检测
小模型识别模块	六类行为分类
语义映射模块	将骨架行为转换为语义信息
大模型推理模块	细粒度行为语义判断
协同决策模块	综合大小模型结果
蒸馏模块	大模型知识迁移

增量学习模块	新数据加入和模型升级
可视化模块	展示识别结果

第 4 章 数据处理与骨架特征构建

本系统采用基于人体骨架的行为识别方案。原始视频首先经过视频解码和时序采样，再使用经过 INT8 量化的 RTMDet-S INT8 和 RTMPose-S 模型分别进行人体检测和关键点提取。针对校园交互行为中常见的双人场景，系统进一步通过时序轨迹关联保持人物身份的一致性，并最终形成统一的 COCO17 Skeleton Sequence，供后续轻量级行为识别模型使用。

整体数据预处理流程（RGB 流）



4.1 数据输入

系统输入为校园场景视频：

$$\mathcal{V} = \{I_0, I_1, \dots, I_{N-1}\}$$

其中， I_i 表示第 i 帧图像， N 表示视频总帧数，原始视频帧率记为 f_s ，图像宽、高分别为 WW 和 HH 。

系统支持 MP4、AVI 等常见视频格式。视频读取阶段主要检查视频是否可以正常打开、是否存在可解码帧，以及 FPS、分辨率等基本信息是否有效。

当视频无法提供有效帧率时，可采用默认帧率：

$$f_s = 30 \text{ FPS}$$

以保证后续时序处理正常进行。

4.2 视频帧处理

4.2.1 帧采样

为降低姿态估计计算开销，同时尽可能保留完整动作过程，系统对原始视频进行时序采样。

设最大采样帧数为 $T_{\max}$ 。当：

$$N \leq T_{\max}$$

时，保留全部有效帧；当：

$$N > T_{\max}$$

时，在整个视频范围内进行均匀采样。

第 k 个采样帧位置为：

$$i_k = \text{round} \left(\frac{k(N-1)}{T_{\max}-1} \right), \quad k = 0, 1, \dots, T_{\max}-1$$

这种方法能够使采样帧覆盖动作的开始、发展和结束阶段，避免仅截取视频局部片段。

系统同时支持帧间隔参数 ss ，仅处理满足：

$$i \bmod s = 0$$

的帧。实时推理场景下通常设置：

$$s = 1$$

即逐帧执行姿态估计。

4.2.2 图像预处理

采样得到的第 t 帧表示为：

$$I_t \in \mathbb{R}^{H \times W \times 3}$$

图像直接送入人体检测与 RTMPose 推理流水线。模型所需的尺寸调整、归一化和 Tensor 转换由姿态估计推理框架统一完成。

4.3 人体检测与多人姿态估计

本系统采用 RTMDet-S + RTMPose-S 组成轻量级 Top-down 人体姿态估计流水线。

其中，RTMDet-S 负责在视频帧中定位人体，RTMPose-S 负责在检测到的人体区域中进一步预测人体关键点。

整体过程可表示为：

$$I_t \xrightarrow{\text{RTMDet-S}} B_t^m \xrightarrow{\text{RTMPose-S}} P_t^m$$

其中：

- I_t : 第 t 帧图像；
- B_t^m : 第帧中第 m 个人的人体检测框；
- P_t^m : 该人体对应的 COCO17 骨架关键点。

两个模型均采用 INT8 量化，以降低边缘侧推理的模型存储空间和计算开销。

4.3.1 RTMDet-S 人体检测

对于采样得到的第 t 帧图像：

$$I_t \in \mathbb{R}^{H \times W \times 3}$$

首先使用 RTMDet-S 完成人体检测。

RTMDet-S 输出当前图像中的候选人体边界框集合：

$$D_t = \{B_t^1, B_t^2, \dots, B_t^K\}$$

其中，第 m 个检测结果表示为：

$$B_t^m = (x_1, y_1, x_2, y_2, s_{\text{det}})$$

其中：

- x_1, y_1 ：人体框左上角坐标；
- x_2, y_2 ：人体框右下角坐标；
- s_{det} ：人体检测置信度。

系统设置人体检测置信度阈值：

$$x = 0.15\tau_{\text{bbox}} = 0.15$$

仅保留满足：

$$s_{\text{det}} \geq \tau_{\text{bbox}}$$

的人体候选框。

随后采用非极大值抑制（Non-Maximum Suppression, NMS）去除高度重叠的重复人体框。NMS 的 IoU 阈值设置为：

$$S = 0.5\tau_{\text{NMS}} = 0.5$$

经过置信度过滤和 NMS 后，得到最终有效人体检测框，并送入 RTMPose-S 进行关键点估计。

因此，该阶段完成：

$$I_t \rightarrow \{B_t^1, B_t^2, \dots, B_t^K\}$$

即从完整视频帧中确定“人体位于什么位置”。

4.3.2 RTMPose-S 姿态估计

对于 RTMDet-S 检测到的每一个有效人体框 B_t^m ，系统截取或映射对应人体区域，并输入 RTMPose-S 进行二维姿态估计。

对于第 t 帧中的第 m 个人，RTMPose-S 输出：

$$P_t^m = \{p_{t,1}^m, p_{t,2}^m, \dots, p_{t,17}^m\}$$

其中，第 j 个关键点表示为：

$$p_{t,j}^m = (x_{t,j}^m, y_{t,j}^m, s_{t,j}^m)$$

其中：

- $x_{t,j}^m$: 第 j 个关节点的横坐标；
- $y_{t,j}^m$: 第 j 个关节点的纵坐标；
- $s_{t,j}^m$: 该关节点的预测置信度。

因此 RTMPose-S 完成：

$$(I_t, B_t^m) \rightarrow P_t^m$$

即在 RTMDet-S 已确定人体位置的基础上，进一步判断“人体各关节位于什么位置”。

RTMDet-S 和 RTMPose-S 的功能分工如下：

模型	主要功能	输入	输出
RTMDet-S INT8	人体检测与定位	视频帧	Person Bounding Boxes
RTMPose-S INT8	人体姿态估计	人体区域	COCO17 Keypoints

4.3.3 COCO17 骨架关键点

RTMPose-S 最终输出标准 COCO17 二维人体骨架，共包含 17 个关键点。

编号	英文名称	中文名称	人体区域
0	Nose	鼻子	头部
1	Left Eye	左眼	头部
2	Right Eye	右眼	头部
3	Left Ear	左耳	头部
4	Right Ear	右耳	头部
5	Left Shoulder	左肩	上肢 / 躯干
6	Right Shoulder	右肩	上肢 / 躯干
7	Left Elbow	左肘	上肢
8	Right Elbow	右肘	上肢
9	Left Wrist	左手腕	上肢
10	Right Wrist	右手腕	上肢

11	Left Hip	左髋	躯干 / 下肢
12	Right Hip	右髋	躯干 / 下肢
13	Left Knee	左膝	下肢
14	Right Knee	右膝	下肢
15	Left Ankle	左脚踝	下肢
16	Right Ankle	右脚踝	下肢

COCO17 骨架覆盖人体头部、躯干、双臂和双腿等主要结构。其中，肩部、肘部和手腕关键点可以反映挥手、推搡等上肢动作；髋部、膝部和脚踝关键点可以描述行走、奔跑、追逐等下肢运动；不同人物之间关键点位置随时间的变化还可以进一步反映双方接近、远离及身体交互等行为特征。

因此，COCO17 能够以较低的数据维度保留校园行为识别所需的主要人体运动信息。

4.4 人体关联与跟踪

单帧姿态估计只能判断当前帧中存在的人体，而行为识别需要保证同一人物在连续帧中的身份一致。因此，本系统采用基于 Bounding Box IoU 与中心距离的轻量级贪心跟踪算法进行跨帧人物关联。

4.4.1 IoU 匹配

设历史轨迹框为 B^{track} ，当前检测框为 B^{det} ，两者的交并比定义为：

$$\frac{|B^{track} \cap B^{det}|}{|B^{track} \cup B^{det}|}$$

IoU 越大，说明两个检测框在空间位置上越接近。

4.4.2 中心距离

考虑到快速运动时相邻帧的人体框可能重叠较少，系统同时计算归一化中心距离。

人体框中心定义为：

$$\left(\frac{x_1 + x_2}{2}, \frac{y_1 + y_2}{2} \right)$$

归一化中心距离定义为：

$$d = \frac{\|c(B^{track}) - c(B^{det})\|_2}{\max(diag(B^{track}), diag(B^{det}), 1)}$$

其中 $diag(B)diag(B)$ 表示人体框对角线长度。

当满足：

$$IoU \geq 0.05$$

或：

$$d \leq 0.55$$

时，将该检测视为历史轨迹的候选匹配。

候选匹配得分定义为：

$$e_{match} = IoU - 0.15d$$

系统按照匹配得分从高到低进行贪心分配，并保证一个检测框只能对应一条轨迹。

4.4.3 短时遮挡处理

校园场景中可能出现人体遮挡或短时间漏检，因此系统允许轨迹短时间失去观测。

设当前帧与轨迹最后出现帧之间的间隔为：

$$\Delta t = t - t_{last}$$

当：

$$\Delta t \leq G_{\max}$$

时，该轨迹仍然参与后续匹配。

系统采用：

$$G_{\max} = 6s$$

其中 ss 为帧采样间隔。

4.4.4 双人轨迹选择

由于视频中可能存在背景行人，本系统不直接采用最先检测到的两个人，而根据轨迹持续时间、检测置信度和人体框大小进行排序。

第 m 条轨迹的评分定义为：

$$R_m = N_m \cdot \bar{s}_m \cdot \left(1 + \frac{\sqrt{\text{median}(A_m)}}{1000} \right)$$

其中：

- N_m ：该轨迹的有效观测帧数；
- $\bar{s}_m$ ：平均人体检测置信度；
- A_m ：轨迹对应的人体框面积。

最终选取得分最高的两条轨迹：

$$M \leq 2$$

作为后续行为识别的主要人物。

4.5 坐标归一化

RTMPose 原始输出为图像像素坐标 $(x,y)(x,y)$ 。为了消除不同视频分辨率带来的影响，将坐标归一化至 $[0,1][0,1]$ 范围。

对于图像宽度 WW 和高度 HH ：

$$\tilde{x} = \frac{x}{W}$$

$$\tilde{y} = \frac{y}{H}$$

因此每一个关键点表示为：

$$\tilde{p}_{t,j}^m = (\tilde{x}_{t,j}^m, \tilde{y}_{t,j}^m)$$

经过归一化后，不同分辨率的视频均具有统一的坐标尺度，便于后续模型进行时空特征学习。

4.6 时序质量控制与关键点处理

4.6.1 关键点置信度过滤

RTMPose 为每一个关键点输出置信度：

$$s_{t,j}^m \in [0, 1]$$

系统设置关键点有效阈值：

$$\tau_{kp} = 0.20$$

定义有效性掩码：

$$Mask_{t,j}^m = \begin{cases} 1, & s_{t,j}^m \geq \tau_{kp} \\ 0, & s_{t,j}^m < \tau_{kp} \end{cases}$$

最终得到：

$$\in \{0, 1\}^{M \times T \times 17}$$

低置信度关键点不会导致整帧被删除，而是通过 Mask 标记其有效性，从而尽量保留其他可靠人体关节信息。

4.6.2 人体缺失处理

当某一帧中某一人物未被检测到时，系统保持原有时间位置，并将对应骨架坐标和关键点置信度置零：

$$X_{m,t,:} = 0$$

$$S_{m,t,:} = 0$$

这样可以保持时间序列结构完整，并避免因直接删除帧而破坏动作时序关系。

4.6.3 时序平滑与插值

当前主推理链路不过度使用时序平滑，因为推搡、挥手和快速追逐等行为本身包含较明显的高频运动信息，过强滤波可能削弱有效动作特征。

系统主要依赖：

关键点置信度 + 人体跟踪 + 有效性 Mask

完成质量控制。

对于少量连续缺失的关键点，可选用线性插值。若关键点在 t_a 与 t_b 时刻有效，则中间位置可表示为：

$$\frac{t - t_a}{t_b - t_a} (P_{t_b} - P_{t_a}), \quad t_a < t < t_b$$

仅对较短缺失区间进行插值，较长时间缺失仍保持无效状态，以避免人为生成错误运动轨迹。

4.7 输出格式

当前系统直接保留 RTMPose 输出的 COCO17 二维骨架表示。最终单个视频的骨架数据表示为：

$$X \in \mathbb{R}^{M \times T \times V \times C}$$

其中：

- M：最多保留的人数，本系统取 $M=2$ ；
- T：视频经过采样后的帧数；
- V：人体关键点数量，COCO 格式下 $V=17$ ；
- C：关键点坐标维度，本系统采用二维坐标，因此 $C=2$ 。

另外保存关键点置信度：

$$S \in \mathbb{R}^{M \times T \times V}$$

用于表示每一个关键点的检测可信程度。

以及关键点有效性掩码：

$$\in \{0, 1\}^{2 \times T \times 17}$$

其中：

$$\text{Mask}_{m,t,j} = [S_{m,t,j} \geq 0.20]$$

第 5 章 语义增强的轻量级骨架行为识别模型设计

本系统面向校园场景中的细粒度行为识别任务，在轻量级骨架图卷积网络 ProtoGCN 的基础上，引入生成式动作描述驱动的图—文本语义对齐机制。一方面，利用 ProtoGCN 对人体关节之间的动态拓扑关系进行建模，通过运动拓扑增强和原型重构突出相似动作之间的细粒度差异；另一方面，借鉴 Generative Action Description Prompts (GAP) 的跨模态对比学习思想，将行为类别的自然语言语义作为训练阶段的辅助监督，使骨架特征不仅具有运动结构上的判别能力，同时获得更明确的动作语义约束。

针对“嬉戏追逐—冲突追逐”“嬉戏推搡—冲突推搡”等骨架运动模式高度相似的校园行为，本系统最终形成“拓扑结构判别 + 原型差异强化 + 动作语义约束”的三级特征学习机制。


5.1 模型训练总体思路

本系统采用“大规模动作数据预训练 + 校园六分类全量微调”的两阶段训练策略，而不是直接利用规模较小的校园行为数据从零训练模型。

整体训练流程可以表示为：

代码片段 (plain text)

```
阶段一: Kinetics-400 骨架动作预训练
Kinetics Skeleton 2D
    ↓
骨架采样 / Kinetics_Transform / coco_new 图构建
    ↓
ProtoGCN Backbone
GCN Block + MSTCN + MTE
    ↓
Prototype Reconstruction Network (PRN)
    ↓
400 类行为分类
    ↓
```



这样的训练方式主要解决两个问题：一方面，Kinetics-400 提供大量通用人体动作样本，使模型首先学习稳定的关节运动模式、人体拓扑关系及时间动态；另一方面，校园数据微调进一步把这些通用运动知识适配到 l_{walk} 、 l_{run} 、 l_{chase} 、 l_{push} 、 t_{chase} 、 t_{push} 六个目标类别，尤其强化“嬉戏—冲突”等细粒度行为之间的区分能力。六类标签与当前工程定义保持一致。

5.2 阶段一：基于 Kinetics-400 的骨架动作预训练

5.2.1 骨架输入与时空图构建

预训练阶段使用 Kinetics Skeleton 2D 数据。

对于每个动作样本，首先对完整骨架序列进行均匀时间采样，将序列统一为 100 帧；对于多人场景，最多保留 2 名主要人物。随后通过 Kinetics Transform 将关键点统一转换至 ProtoGCN 使用的 o_{new} 图结构。

当前模型使用 joint modality, 即直接以人体关键点位置作为基础骨架特征。Kinetics-400 配置中采用 $p_{len}=100$ 、 $m_{person}=2$ 和 o_{new} 图结构。

对于连续骨架序列，可以将其抽象为时空图：

$$G=(V,E), G=(V,E),$$

其中：

- V 表示人体关键点节点；
- 空间边描述同一帧中人体骨骼的天然连接关系；
- 时间边描述连续时间帧中同一关键点之间的运动关联。

因此，原始人体骨架序列被转换为一个 Spatio-Temporal Graph，后续所有特征学习均建立在该图结构之上。

5.3 ProtoGCN 主干：从关节运动到细粒度拓扑特征

普通 GCN 能够利用人体骨骼连接传播关节信息，但对于 $l_p\text{ush}$ 与 $t_p\text{ush}$ 、 $l_c\text{hase}$ 与 $t_c\text{hase}$ 这类行为而言，参与运动的身体部位往往高度相似。

真正决定类别的并不只是“哪些关节发生了运动”，还包括：

- 关节运动幅度；
- 不同身体部位之间的协同关系；
- 人与人之间距离变化；
- 局部关节运动的细微差异。

因此，本系统采用 ProtoGCN 作为骨架特征提取主干，通过 Motion Topology Enhancement (MTE) + Prototype Reconstruction Network (PRN) + Class-Specific Contrastive Learning (CSCL) 对动作关系进行进一步建模。

5.3.1 GCN Block 与多尺度时间建模

ProtoGCN 的基本网络单元由图卷积和多尺度时间卷积组成。

其中，GCN 主要负责建模同一时间帧内不同人体关节之间的空间依赖关系；MSTCN 则从多个时间尺度建模人体动作动态，使模型同时获取：

$$\text{Spatial Relation} + \text{Temporal Motion}.$$

即一方面判断“身体哪些部位存在运动关联”，另一方面学习“这些关联如何随时间发生变化”。

当前 ProtoGCN 实现也是按照 GCN、MSTCN 和残差连接组成多层时空特征提取网络。

5.4 MTE：增强样本相关的细粒度运动拓扑

传统 GCN 大多基于固定人体骨骼结构或跨样本共享的可学习图结构进行建模，但是不同动作样本中的真实关节关系并不完全相同。

例如，“正常行走”和“正常跑步”都涉及双腿交替运动，但跑步动作中的膝关节弯曲程度、步幅、上肢摆动幅度以及躯干移动速度明显更大。

因此 ProtoGCN 通过 Motion Topology Enhancement，进一步建立与当前样本相关的动态关节关系。

设某层输入特征为 $\mathbf{H}$ ，首先计算 Query 与 Key：

$$\mathbf{H}^Q = \text{AvgPool}_T(\mathbf{H}\mathbf{W}_Q), \quad \mathbf{H}^K = \text{AvgPool}_T(\mathbf{H}\mathbf{W}_K).$$

随后建模当前样本中的整体关节相关性：

$$\mathbf{A}_{intra} = \phi_{\langle intra \rangle} (\mathbf{H}^Q (\mathbf{H}^K)^\top).$$

同时通过两两特征差异进一步描述关节之间的细粒度区别：

$$\mathbf{A}_{inter} = \phi_{\langle inter \rangle} (\mathcal{T}_1(\mathbf{H}^Q) - \mathcal{T}_2(\mathbf{H}^K)).$$

最终将人体基础拓扑与动态学习到的拓扑共同用于图卷积：

$$\mathbf{H}^{(l)} = \sigma [(\mathbf{A}_0 + \mathbf{A}_{intra} + \mathbf{A}_{inter}) \mathbf{H}^{(l-1)} \mathbf{W}^{(l)}].$$

其中：

$$\mathbf{A}_0$$

描述人体共有的基础骨骼连接关系；

$$\mathbf{A}_{intra}$$

描述当前动作内部不同关节之间的整体相关性；

$$\mathbf{A}_{inter}$$

进一步保留不同关节运动模式之间的细粒度差异。

因此 MTE 的作用并不是简单地增加一个动态邻接矩阵，而是让模型同时学习

“哪些关节共同运动”以及“它们具体如何不同地运动”。上述形式与 ProtoGCN 中的 MTE 定义保持一致。

5.5 PRN：基于运动原型重构高层关节关系

经过多层 GCN 与 MTE 后得到的高层动态图结构仍然可能包含姿态检测误差、遮挡以及偶然动作产生的无关关系。

因此 ProtoGCN 在高层动态图之后引入 Prototype Reconstruction Network (PRN)。

设最终学习到的高层关系图为：

$$\mathbf{A} \in \mathbb{R}^{N \times N \times C}.$$

将其展开得到：

$$\mathbf{X} \in \mathbb{R}^{N^2 \times C}.$$

这里 $\mathbf{X}$ 的每一行都可以理解为一个“关节对”的高维关系表示。

PRN 内部维护一个可学习的原型记忆空间。首先根据当前关系特征计算其对不同 prototype 的响应：

$$R = \text{softmax}(\mathbf{X}\mathbf{W}_{query}^T) \in \mathbb{R}^{N^2 \times n_{pro}}.$$

随后按照这些响应权重重新组合 prototype：

$$\mathbf{W}_{memory} \in \mathbb{R}^{N^2 \times C}.$$

因此可以将整个过程概括为：

$$\mathbf{X} \rightarrow \text{Prototype Assignment} \rightarrow \mathbf{R} \rightarrow \text{Prototype Memory} \rightarrow \mathbf{Z}.$$

这里的 prototype 并不是某个固定动作类别，也不是简单对应“手”“脚”等身体区域，而是一种模型自动学习得到的抽象关节关系模式。

通过 prototype bottleneck，高层图关系不再完全依赖单一样本，而需要利用训练数据中学习到的典型运动关系重新表达，从而抑制部分偶然噪声，并突出更加稳定、具有判别性的运动模式。

当前模型使用：

$$n_{pro} = 400,$$

即维护 400 个运动关系 prototype。

5.6 CSCL: 增强原型重构结果的类别判别能力

PRN 保证了高层图关系可以通过一组 prototype 进行重构, 但是仅完成 prototype 重构并不能保证这些关系一定具有类别判别能力。

因此 ProtoGCN 又引入 Class-Specific Contrastive Learning (CSCL)。

对于第 k 类动作, 设其类别聚合中心为:

$$\mathbf{m}_k.$$

当前 batch 中属于第 k 类的平均特征记为:

$$\bar{\mathbf{f}}_k.$$

类别中心采用动量更新:

$$\mathbf{m}_k = \alpha \mathbf{m}_k + (1 - \alpha) \bar{\mathbf{f}}_k.$$

对于类别 k 中的某一个样本 $\mathbf{f}_{k,j}$, 定义:

$$\mathcal{L}_{CSC} = -\log \frac{\exp(\mathbf{f}_{k,j} \cdot \mathbf{m}_k / \tau)}{\exp(\mathbf{f}_{k,j} \cdot \mathbf{m}_k / \tau) + \sum_{l \neq k} \exp(\mathbf{f}_{k,j} \cdot \mathbf{m}_l / \tau)}.$$

其本质包括两个方向:

Compactness: 类内紧凑性

$$\mathbf{f}_{k,j} \rightarrow \mathbf{m}_k$$

使相同行为类别的高层关系更加接近。

Dispersion: 类间分离性

$$\mathbf{f}_{k,j} \not\rightarrow \mathbf{m}_l, \quad l \neq k$$

使不同动作类别的高层关系尽可能分离。

对于校园行为而言，这种机制特别适用于区分运动结构高度相似的类别，例如：

$$\text{playful chase} \leftrightarrow \text{conflict chase}$$

以及

$$\text{playful push} \leftrightarrow \text{conflict push}.$$

因此 Kinetics-400 预训练阶段的主要优化目标为：

$$\mathcal{L}_{\text{pretrain}} = \mathcal{L}_{CE}^{K400} + \lambda_{CSC} \mathcal{L}_{CSC}$$

当前 ProtoGCN 中：

$$C = 0.2, \lambda_{CSC} = 0.2.$$

因此：

$$\mathcal{L}_{\text{pretrain}} = \mathcal{L}_{CE}^{K400} + 0.2 \mathcal{L}_{CSC}$$

这也与仓库当前分类 Head 中的实际损失组合一致。

5.7 阶段一训练结果：获得通用人体动作先验

Kinetics-400 包含大量不同类型的人体动作，因此其主要作用并不是直接解决 Campus6 的六分类问题，而是让 ProtoGCN 提前获得较为稳定的人体运动先验。

经过 Kinetics-400 训练后，模型能够学习：

- 常见人体关节之间的空间关联；
- 不同运动速度与运动幅度；
- 上肢、下肢和躯干之间的动态协同；
- 多种动作对应的典型 prototype 关系模式；
- 具有类别判别能力的高层骨架表示。

在这一阶段，模型使用 Kinetics 的 400 类分类任务进行训练，最终保存训练得到的 ProtoGCN Backbone 权重：

$$\theta_{K400}.$$

该参数作为第二阶段 Campus6 模型的初始化：

$$\theta_{\text{Campus6}}^{(0)} \leftarrow \theta_{\text{K400}}.$$

5.8 阶段二：Campus6 六分类全参数微调

第二阶段使用校园行为数据对 Kinetics 预训练模型进行全参数微调。

首先加载 Kinetics-400 预训练得到的 ProtoGCN Backbone，然后将原来的：

```
-class Head
```

替换为：

```
-class Head.
```

当前六类目标行为包括：

```
{normal walk, normal run, playful chase, playful push, conflict chase, conflict push}.
```

这里采用的是 Full Fine-tuning，并不是只训练最后的六分类层。

也就是说，包括 GCN、MSTCN、动态拓扑学习模块以及 PRN 在内的 Backbone 参数都会继续根据 Campus6 数据进行反向传播更新。

当前 Campus6 工程正是从 Kinetics Skeleton 2D 的 ProtoGCN Backbone 初始化模型，并使用 6 类分类头继续训练；微调阶段采用较小学习率 0.0030.003，训练 40 epochs。

这种方式使模型首先从 Kinetics 学习“通用人体运动”，随后再将这些运动知识适配至更加细粒度的校园行为。

5.9 GAP：利用动作自然语言描述辅助 Campus6 微调

仅依赖骨架运动结构时，某些校园行为仍然存在明显的语义模糊问题。

例如：

```
playful chase
```

和

conflict chase

在骨架层面都可能表现为“两个人跑动”。

类似地：

playful push

和

conflict push

都可能出现“双人接触、上肢运动和身体位置变化”。

因此，仅告诉网络“这是哪一个类别”可能还不足以显式表达两个类别究竟差在哪里。

为此，本系统借鉴 Generative Action Description Prompts for Skeleton-based Action Recognition (GAP) 的思想，将自然语言动作描述作为辅助监督引入训练阶段。

GAP 的核心思想是将骨架特征与文本特征映射至同一个语义空间，通过特征相似度建立骨架动作与自然语言语义之间的对应关系。

对于两个已经 L2 归一化的特征：

$$\hat{\mathbf{x}}_1, \quad \hat{\mathbf{x}}_2,$$

二者之间的内积即为余弦相似度：

$$s = \hat{\mathbf{x}}_1 \hat{\mathbf{x}}_2^\top.$$

原始 GAP 方法进一步利用标签关系构造 Ground Truth 相似度矩阵，并使用 KL 散度约束预测语义关系，其 KL 散度为：

$$D_{\text{KL}}(P \parallel Q) = \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right).$$

上述思想与项目已有 GAP 学习页面中所总结的“特征归一化—相似度矩阵—语义对齐”过程保持一致。

5.9.1 Campus6 身体部位级动作语义 Prompt

为了向骨架特征提供更加明确的行为语义监督，本系统针对 Campus6 六类行为分别构造 Global、Head、Arms、Torso、Legs 五个身体层级的动作描述。与只使用类别名称相比，这些描述能够显式表达动作速度、运动幅度、身体协同关系以及双人相对距离变化等细粒度判别依据。

行为类别	Global	Head	Arms	Torso	Legs
Normal Walk	a person walking	head moves with body direction	arms swing alternately forward and backward with low amplitude and small elbow bending	torso translates steadily forward	legs step alternately with short strides and small knee bending
Normal Run	a person running	head moves with body direction	arms swing quickly forward and backward with clear elbow bending	torso leans and translates quickly forward	legs stride quickly in alternation with clear knee bending
Playful Chase	two people running	no fixed motion pattern	no fixed motion pattern	no fixed motion pattern	no fixed motion pattern
Playful Push	two people make contact	heads remain near the interacting torsos	no fixed motion pattern	the two torsos do not move clearly farther apart	feet make small adjustments for balance
Conflict Chase	one person runs quickly behind another person	no fixed motion pattern	no fixed motion pattern	the distance between the two people changes quickly	no fixed motion pattern

Conflict Push	two people make contact and the distance between them changes substantially	no fixed motion pattern	no fixed motion pattern	after contact the distance between the two people changes substantially	no fixed motion pattern
---------------	---	-------------------------	-------------------------	---	-------------------------

这里的 Prompt 设计并不要求每一个身体部位都必须具有明确、固定的运动模式。对于缺少稳定局部规律的行为，直接使用 “no fixed motion pattern”，避免为了增加文本信息而人为引入并不存在的动作先验。

5.10 文本描述的语义编码

上述六类行为，每个类别包含 5 条身体部位描述，因此共形成：

$$6 \times 5 = 30$$

条动作语义描述。
使用冻结的 CLIP 文本编码器对这些描述进行编码，得到：

$$\mathbf{T} \in \mathbb{R}^{6 \times 5 \times 512}.$$

其中：
66
表示六个 Campus6 行为类别；
55
表示 Global、Head、Arms、Torso 和 Legs 五个身体语义区域；
512512
表示文本语义特征维度。

这些文本特征在训练前预先生成，并作为固定的语义监督目标保存，因此在 Campus6 训练过程中不需要继续更新 CLIP 文本编码器。

当前工程中的 GAP recognizer 实际加载的文本特征形状也正是：
[6,5,512].[6,5,512].

5.11 身体部位骨架特征提取

设 ProtoGCN 输出的高层骨架特征为：

$$\mathbf{F} \in \mathbb{R}^{N \times M \times C \times T \times V}.$$

其中：

- NN：batch size；
- MM：人物数量；
- CC：特征通道数；
- TT：时间长度；
- VV：关键点数量。

为了与五组文本语义进行对齐，将人体关键点划分为：

$$P = \{P_{global}, P_{head}, P_{arms}, P_{torso}, P_{legs}\}.$$

对于某一个身体区域 pp，在人物维、时间维和该区域对应的关节维上执行平均池化：

$$f_i^{(p)} = \text{AvgPool}_{M,T,V_p}(\mathbf{F}_i).$$

这样即可获得当前样本在某个身体区域上的骨架动作表示。

需要注意的是，架构图中的“手腕”建议统一修改为“上肢 Arms”，因为实际工程中的这一分支不仅包含 wrist，还包含 shoulder、elbow 和 wrist，即完整的上肢运动信息。

5.12 骨架—文本语义对齐

由于 ProtoGCN 骨架特征与 CLIP 文本特征位于不同的表示空间，因此对于每一个身体区域设置一个可学习线性投影：

$$\mathbf{v}_i^{(p)} = \mathbf{W}_p \mathbf{f}_i^{(p)}.$$

将其投影至 512 维文本语义空间：

$$v_i^{(p)} \in \mathbb{R}^{512}.$$

随后对骨架特征和文本特征分别执行 L2 归一化：

$$\hat{\mathbf{v}}_i^{(p)} = \frac{\mathbf{v}_i^{(p)}}{\|\mathbf{v}_i^{(p)}\|_2},$$

$$\hat{\mathbf{t}}_c^{(p)} = \frac{\mathbf{t}_c^{(p)}}{\|\mathbf{t}_c^{(p)}\|_2}.$$

由此计算第 i 个骨架样本与第 c 类文本描述之间的相似度：

$$\frac{\hat{\mathbf{v}}_i^{(p)} \cdot \hat{\mathbf{t}}_c^{(p)}}{\tau}.$$

其中：

$$\tau$$

为温度参数。

当前项目设置：

$$\tau = 0.07.$$

因此，对于一个属于 $l_r\text{un}$ 的骨架样本，理想状态下其 Legs 特征应更加接近：

legs stride quickly in alternation with clear knee bending

而不应该更加接近 normal walk 中：

legs step alternately with short strides and small knee bending

这样模型就不仅知道两个样本分别属于哪个类别，还能够学习：

short strides $\leftrightarrow$ fast strides,

以及：

small knee bending $\leftrightarrow$ clear knee bending

这样的更细粒度语义差异。

5.13 GAP 身体部位语义损失

对于每个身体区域，都可以得到当前骨架样本与六个文本类别之间的相似度：

$$\mathbf{s}_i^{(p)} = [s_{i,1}^{(p)}, s_{i,2}^{(p)}, \dots, s_{i,6}^{(p)}].$$

利用真实行为类别 y_i ，分别计算各身体区域的语义分类损失：

$$\mathcal{L}_{GAP}^{(p)} = CE(\mathbf{s}_i^{(p)}, y_i).$$

随后对五个身体区域求平均：

$$\mathcal{L}_{GAP} = \frac{1}{5} \sum_{p=1}^5 \mathcal{L}_{GAP}^{(p)}$$

因此每一个训练样本实际上会同时收到五组语义约束：

$$\text{Global} + \text{Head} + \text{Arms} + \text{Torso} + \text{Legs}.$$

这种方式保留了 GAP 中“骨架特征—动作文本特征语义对齐”的核心思想，但针对 Campus6 已知六类标签的监督学习任务，采用 class-wise Cross Entropy 完成更加直接的语义约束。当前 RecognizerGCNGAP 的实际实现也是对 5 个身体区域分别计算相似度和 Cross Entropy，再取平均。

5.14 Campus6 微调阶段联合损失

Campus6 阶段最终同时受到三类监督。

第一部分为六分类 Cross Entropy：

$$\mathcal{L}_{CE}.$$

它负责保证模型能够正确预测最终行为类别。

第二部分为 ProtoGCN 的类别特异对比损失：

$$\mathcal{L}_{CSC}.$$

它利用 PRN 重构后的高层图关系约束同类动作更加聚合、不同动作更加分离。

第三部分为 GAP 身体部位动作语义损失：

$$\mathcal{L}_{GAP}.$$

它利用动作自然语言描述约束骨架特征具有更加明确的行为语义。

因此 Campus6 微调阶段的最终优化目标为：

$$\mathcal{L}_{\text{Campus6}} = \mathcal{L}_{CE} + \lambda_{CSC} \mathcal{L}_{CSC} + \lambda_{GAP} \mathcal{L}_{GAP}$$

当前工程中：

$$C = 0.2, \lambda_{CSC} = 0.2,$$

$$P = 0.15, \lambda_{GAP} = 0.15,$$

$$\tau = 0.07.$$

因此：

$$\mathcal{L}_{\text{Campus6}} = \mathcal{L}_{CE} + 0.2 \mathcal{L}_{CSC} + 0.15 \mathcal{L}_{GAP}$$

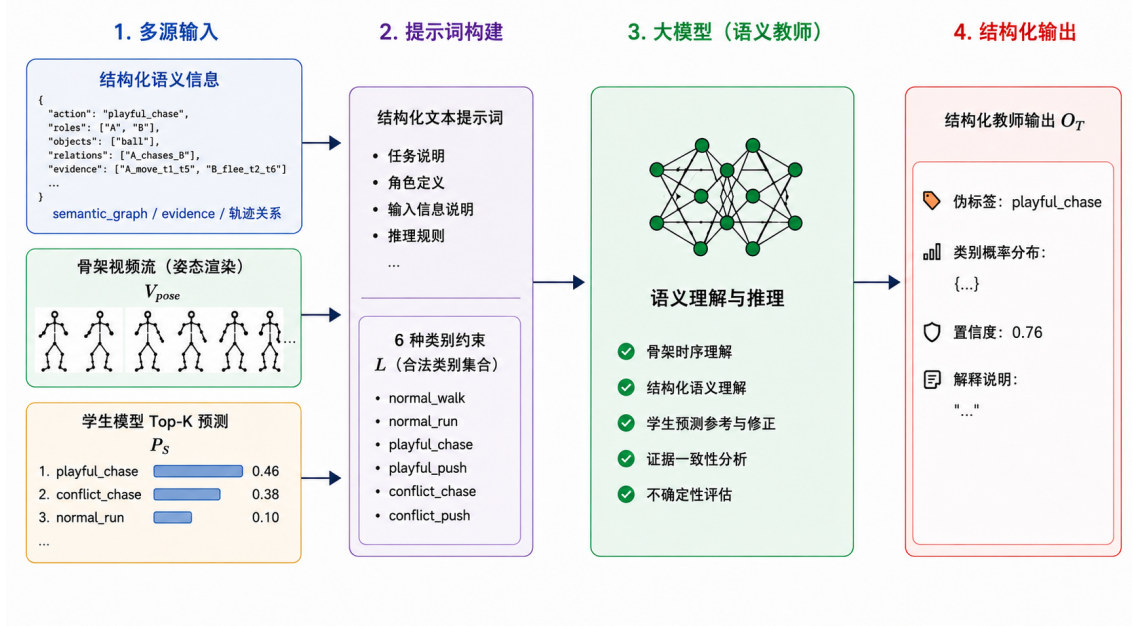
这些参数与当前 Campus6 GAP 配置保持一致。

第 6 章 大模型语义理解设计

轻量级行为识别模型主要基于人体骨架序列进行时空图建模，通过 GCN 学习关节之间的空间关系以及动作随时间变化的动态模式。该方法能够有效提取速度、姿态变化、关节协同运动等判别性特征，对于步行、奔跑等具有明显运动模式差异的行为具有较好的识别能力。

然而，对于“玩闹追逐与冲突追逐”“玩闹推搡与冲突推搡”等细粒度行为，其底层人体运动模式具有较高相似性。此时，仅依赖 GCN 从骨架序列中学习得到的时空判别特征，可能难以充分刻画人物之间的交互性质和行为语义，从而导致类别混淆。

因此，本项目引入多模态大模型作为语义教师，语义教师采用与具体模型解耦的接口设计。系统仅要求所接入模型具备骨架时序理解、结构化文本理解、封闭类别推理以及结构化结果生成能力。当前实现采用 Qwen3-VL-8B-Instruct 作为推理后端，在保持输入输出协议不变的情况下，也可替换为其他具备相同能力的大模型。多模态大模型推理的整体流程如下。



注：在实际构建中，我们可能并没有三种输入数据，而我们的多模态推理模块则会采用实际可获得的数据类型进行推理。

6.1 多源输入

语义教师并非单独依据学生模型的分类结果重新判断，而是同时接收骨架视频流、结构化语义信息和学生模型预测结果，从不同信息层面对同一行为片段进行描述。

整体输入定义为：

$$I_T = \{V_{\text{pose}}, G_{\text{sem}}, P_S\}$$

三类信息具有不同作用。

6.1.1 结构化语义信息

原始 RGB 视频仅在边缘端用于人体检测与姿态估计，不作为教师模型输入。系统根据骨架序列进一步构造结构化语义信息，用于描述人物运动状态和交互关系。

结构化语义信息可包括人物数量、姿态质量、运动速度、人物间距离变化、接近或远离关系、主要肢体运动以及其他由骨架序列能够可靠提取的行为特征。

这些信息以结构化字段或文本形式提供给教师模型，使大模型能够在不访问原始 RGB 视频的情况下结合骨架运动和学生模型预测进行语义判断。

6.1.2 骨架视频流

骨架视频由人体姿态估计结果渲染得到，以连续视频形式显式展示人体关键点及骨骼连接随时间的变化。

表示为：

$$V_{\text{pose}} = \{S_1, S_2, \dots, S_N\}$$

其中 S_t 为第 t 帧对应的骨架可视化结果。

与重新构造速度、人物距离、接近关系等人工语义规则不同，本方案直接将骨架序列渲染为视觉信息交给多模态大模型，使模型自行理解：

- 人体姿态变化；
- 肢体运动幅度；
- 人物运动方向；
- 多人之间的位置关系；
- 行为随时间的变化过程。

这样可以保持清晰的模块职责：

姿态模块负责提取人体骨架

大模型负责理解骨架运动所对应的行为语义

避免在大模型之前再次建立一套人工规则式行为分析模块。

当前工程的教师推理接口已经将姿态渲染视频作为 $e_v\text{ideo}$ 传入模型，并在教师后端完成视频解码与输入构造。

教师推理阶段以骨架视频和结构化语义信息作为互补输入：骨架视频侧重人体运动结构，结构化语义信息用于补充人物交互关系、姿态质量以及运动统计等信息。

6.1.3 学生模型 Top-KK 预测

学生模型已经完成基础行为识别，因此教师模型无需忽略已有结果从零开始分类，而是将学生模型的 Top-KK 预测作为候选参考。

定义：

$$P_S = \{(y_1, p_1^S), (y_2, p_2^S), \dots, (y_K, p_K^S)\}$$

其中：

$$\geq p_2^S \geq \dots \geq p_K^S$$

例如：

代码片段 (plain text)

```
playful_chase    0.46
conflict_chase   0.38
normal_run       0.10
...
```

这类结果可以直接反映学生模型当前主要在哪些类别之间产生混淆。

但学生预测只作为大模型的参考信息，不能作为确定标签。当前代码在构造教师 Prompt 时明确规定：

代码片段 (plain text)

Student probabilities are a fallible hint and may be corrected.

即学生模型预测可能存在错误，教师可以根据骨架运动和结构化语义证据进行修正。

因此，多源输入的本质可以概括为：

结构化语义信息 + 骨架运动信息 + 学生候选判断

三者分别提供交互语义、人体运动模式以及轻量模型已有判别结果，共同组成大模型进行高层行为理解的输入基础。

6.2 提示词构建

多模态大模型本质上具有开放式视频理解和文本生成能力，而校园行为识别属于严格的封闭集合分类任务。因此，仅将视频输入模型并询问“这是什么行为”无法保证模型按照系统规定的类别和格式进行输出。

为此，本系统通过结构化 Prompt 明确规定教师模型的角色、识别任务、合法类别、学生预测使用方式、事实约束以及输出格式。

Prompt 与骨架视频、结构化语义信息共同构成教师模型完整输入：

$$X_T = [V_{\text{pose}}, G_{\text{sem}}, \mathcal{P}]$$

其中 Prompt $\mathcal{P}$ 内部进一步包含：

$$\mathcal{P} = \{\mathcal{P}_{\text{role}}, \mathcal{P}_{\text{task}}, \mathcal{P}_{\text{student}}, \mathcal{P}_{\text{label}}, \mathcal{P}_{\text{rule}}, \mathcal{P}_{\text{output}}\}$$

6.2.1 教师角色定义

首先将模型角色限定为封闭集合视频行为分析中的弱监督教师，而不是开放式视频问答模型。

当前工程中真实使用的角色定义为：

代码片段 (plain text)

You are a weak-supervision teacher for closed-set video behavior analysis.

这种角色定义明确了两个边界：

一方面，模型的任务是分类和语义判断，而不是生成任意视频描述；另一方面，教师模型的输出将作为后续协同决策和伪标签生成的信息来源，因此需要保持稳定的类别空间和输出结构。

6.2.2 六分类类别约束

对于当前 Campus6 任务，合法类别集合定义为：

$$L = \{normal_walk, normal_run, playful_chase, playful_push, conflict_chase, conflict_push\}$$

Prompt 将完整标签集合直接提供给教师模型，并规定：

代码片段 (plain text)

label must be selected from Allowed labels.

即：

$$T \in L$$

这样可以避免通用大模型输出诸如 “running after someone” “fighting” “playing” 等虽然自然语言上合理、但无法直接参与系统计算的开放式标签。

6.2.3 学生预测使用约束

学生 Top-KK 分布通过结构化文本输入 Prompt。

当前代码中的教师 Prompt Payload 包括：

代码片段 (plain text)

{
 "sample_id": "...",
 "task": "...",
 "semantic_graph": {...},
 "student_distribution": {...}
}

其中 $t_{distribution}$ 即学生模型给出的候选类别概率。

在当前方案中， c_{graph} 作为结构化语义信息的一部分继续作为核心教师输入，Prompt 同时保留样本信息、任务定义和学生预测；骨架信息通过 e_{video} 提供给大模型。

学生预测对应的规则仍然保留：

代码片段 (plain text)

Student probabilities are a fallible hint and may be corrected.

因此，大模型不会简单执行：

$$y_T = y_S$$

而是根据视觉信息重新判断：

$$(V_{rgb}, V_{pose}, P_S)$$

6.2.4 事实约束与幻觉抑制

行为识别场景中，大模型容易根据动作外观进一步推测人物意图、情绪或者未实际观察到的身体接触，从而产生超出视频证据范围的判断。

当前工程 Prompt 对这一问题进行了明确限制：

代码片段 (plain text)

Use only facts present in INPUT.
Do not invent intent, impact force, fear, attacks,
defense, or contact.

Mark unavailable evidence as unknown.

即教师模型只能依据实际视觉输入和系统提供的信息作出判断，未观察到的信息必须视为未知。

这一规则对于“嬉戏—冲突”类细粒度行为尤为重要。模型不能因为运动幅度较大就自行补充“攻击意图”，也不能因为人物距离较近就自动认定存在身体接触。

6.2.5 当前 Prompt 模板

结合当前工程实现，其核心 Prompt 可以整理为：

代码片段 (plain text)

You are a weak-supervision teacher for closed-set video behavior analysis.

Prompt version: campus6-v1.0

Task: {task}

Allowed labels:

```
[
  "normal_walk",
  "normal_run",
  "playful_chase",
  "playful_push",
  "conflict_chase",
  "conflict_push"
]
```

Rules:

- Use only facts present in INPUT.
- Do not invent intent, impact force, fear, attacks, defense, or contact.
- Mark unavailable evidence as unknown.
- Student probabilities are a fallible hint and may be corrected.
- Return one JSON object only, matching teacher_output.v1.
- label must be selected from Allowed labels.
- distribution probabilities must sum to 1.
- label must be the argmax of distribution.
- confidence must equal distribution[label].

INPUT:

```
{
  "sample_id": "{sample_id}",
  "task": "{task}",
  "student_distribution": {
    ...
  }
}
```

```

}

OUTPUT KEYS:
schema_version,
sample_id,
label,
distribution,
confidence,
reason

```

该模板是在当前代码 Prompt 基础上，按照骨架视频流 + 结构化语义信息方案整理后的教师输入形式。当前代码中的原始版本还包含 c_{graph} 、 $evidence$ 、 $r_{evidence}$ 和 s_{review} 等字段；按照本章新的简化设计，可将主要输出聚焦于伪标签、类别分布、置信度和解释信息。

因此，Prompt 在系统中的作用可以总结为：

开放式多模态模型 $\xrightarrow{\text{Prompt 约束}}$ 封闭集合行为语义教师

6.3 大模型推理

完成多源输入和 Prompt 构造后，骨架视频流、结构化语义信息和学生候选概率共同输入大模型。

语义教师的推理过程表示为：

$$Z_T = F_T(V_{\text{pose}}, G_{\text{sem}}, P_S, \mathcal{P}, L)$$

其中 Z_T 表示大模型生成的原始语义结果。

大模型主要完成三个层面的联合理解。

6.3.1 结构化交互语义理解

结构化语义信息由边缘端根据骨架序列构造，用于描述人物数量、人物间距离变化、运动方向、姿态质量以及主要肢体运动等信息。大模型结合这些结构化证据，对人物交互关系进行高层语义判断。

6.3.2 骨架运动时序理解

骨架视频去除了大量背景和外观信息，将大模型注意力集中到人体关节及其运动变化上。

因此骨架流主要提供：

人体姿态 + 肢体运动 + 整体位移 + 多人相对运动

等信息。

结构化语义信息与骨架视频具有互补性：前者用于表达可从骨架可靠提取的人物交互关系和运动统计，后者用于保留连续的人体姿态与运动结构。联合使用两类信息，可以降低单一信息来源对模型判断的影响。

6.3.3 学生预测参考与语义修正

学生模型输出 P_S 进一步向大模型提供候选类别范围。

例如：

$$\text{playful_chase}) = 0.46$$

$$\text{conflict_chase}) = 0.38$$

说明学生模型已经基本判断当前属于 chase 类行为，但无法稳定区分嬉戏追逐和冲突追逐。

此时，大模型不需要重新在完全开放的行为空间进行搜索，而可以重点判断：

$$\text{playful_chase} \quad \text{vs.} \quad \text{conflict_chase}$$

并根据骨架运动和结构化语义信息重新调整类别概率。

因此教师模型承担的是：

学生候选结果 + 骨架语义证据 → 语义修正

而不是简单复制学生模型结果。

大模型最终形成六类行为上的教师分布：

$$P_T = [p_1^T, p_2^T, \dots, p_6^T]$$

并选择：

$$y_T = \arg \max_{y_i \in L} p_i^T$$

作为教师模型最终给出的伪标签。

6.4 结构化输出

大模型完成行为语义判断后，需要将结果转换为统一的结构化形式，才能进一步用于大小模型协同、伪标签数据构建以及后续知识蒸馏。

因此教师输出定义为：

$$O_T = (y_T, P_T, C_T, R_T)$$

其中：

- y_T 表示教师模型生成的伪标签；
- P_T 表示六类行为上的概率分布；
- C_T 表示教师模型对最终标签的置信度；
- R_T 表示教师模型给出的简要语义解释。

6.4.1 伪标签

教师最终输出一个属于六类标签集合的类别：

$$T \in L$$

例如：

代码片段 (plain text)

"label": "playful_chase"

该结果可作为后续伪标签数据构建的重要信息来源。

需要注意的是，大模型生成的标签并不意味着直接作为最终训练标签使用，其是否进入伪标签数据集以及如何与学生结果进行融合，由后续知识蒸馏和自进化流程负责。

6.4.2 类别概率分布

教师模型同时输出六分类概率分布：

$$P_T = \{P_T(y_1), P_T(y_2), \dots, P_T(y_6)\}$$

经过归一化后满足：

$$0 \leq P_T(y_i) \leq 1$$

以及：

$$\sum_{i=1}^6 P_T(y_i) = 1$$

例如：

代码片段 (plain text)

```
"distribution": {  
  "normal_walk":0.01,  
  "normal_run":0.04,  
  "playful_chase":0.76,  
  "playful_push":0.03,  
  "conflict_chase":0.14,  
  "conflict_push":0.02  
}
```

与单一硬标签相比，完整概率分布保留了教师模型对其他类别的判断信息，在后续知识蒸馏中可以进一步作为软标签使用。

6.4.3 置信度

教师模型置信度定义为最终选中类别对应的概率：

$$C_T = P_T(y_T)$$

例如：

代码片段 (plain text)

"confidence":0.76

同时要求：

$$y_T = \arg \max_y P_T(y)$$

保证教师标签与概率分布保持一致。

6.4.4 语义解释

除分类结果外，教师模型还输出简要解释：

代码片段 (plain text)

"reason": "..."

解释内容用于描述大模型综合骨架运动、结构化语义信息和学生候选结果之后形成当前判断的主要依据。

该字段主要服务于系统可解释性和结果展示，而不直接参与学生模型分类计算。

按照当前简化设计，教师的最终结构化输出可以表示为：

代码片段 (plain text)

{
 "schema_version": "teacher_output.v1",
 "sample_id": "sample_001",
 "label": "playful_chase",
 "distribution": {
 "normal_walk": 0.01,
 "normal_run": 0.04,
 "playful_chase": 0.76,
 "playful_push": 0.03,
 "conflict_chase": 0.14,
 "conflict_push": 0.02
 },
 "confidence": 0.76,
 "reason": "..."
}

由此，轻量模型负责高效率的基础行为判别，大模型则针对高混淆行为进一步融合结构化语义信息、骨架运动信息和学生候选结果完成语义判断，并以标准化结构输出教师伪标签及概率信息，为后续大小模型协同决策和知识蒸馏提供统一输入。

第 7 章 大小模型协同决策机制

7.1 协同架构

大小模型协同决策模块位于学生模型推理和最终行为结果输出之间，其本质并不是再次进行行为特征提取，而是根据多个模型及数据质量信号决定当前样本应该采用哪一种决策路径。

整体流程可以表示为：



7.2 大模型触发策略

为了兼顾识别效果和推理效率，大模型不参与所有样本的识别，而是主要处理学生模型难以稳定判断的样本。系统根据学生模型预测结果和姿态数据质量判断是否需要调用教师模型。

主要考虑以下四类情况。

7.2.1 预测置信度较低

当学生模型最高类别的预测概率较低时，说明模型对当前行为没有形成明确判断。此时直接采用学生模型结果存在较大风险，因此触发教师模型进行进一步分析。

当前系统可将学生模型 Top-1 置信度低于一定阈值作为触发条件，例如：

$$C_S < 0.70$$

阈值主要用于识别困难样本，后续可根据验证集表现进一步调整。

7.2.2 Top-1 与 Top-2 过于接近

仅判断最高类别的置信度并不能完全反映模型的不确定性。

例如学生模型输出：

代码片段 (plain text)	
playful_chase	0.51
conflict_chase	0.47

虽然最高概率超过 0.5，但两个类别之间差距很小，说明模型实际上难以区分当前行为。

因此系统进一步计算 Top-1 与 Top-2 的概率差：

$$p_1 - p_2$$

当 Margin 小于设定阈值时，同样调用教师模型。

该机制主要用于发现“嬉戏追逐—冲突追逐”“嬉戏推搡—冲突推搡”等容易发生混淆的样本。

7.2.3 姿态数据质量较差

学生模型依赖人体骨架进行识别，因此关键点缺失、人体遮挡、跟踪错误等问题都会降低预测结果的可信度。

系统根据有效关键点比例和关键点平均置信度计算姿态质量。当姿态质量低于阈值时，即使学生模型给出了较高分类概率，也将其视为需要进一步确认的样本。

此时教师模型可以利用可用的骨架运动信息和结构化语义信息对学生结果进行补充判断。

需要注意的是，姿态质量较差只表示当前学生模型输入不够可靠，并不意味着学生模型结果一定错误。

7.2.4 预测结果不稳定

对于重复推理或历史预测结果，如果同一样本频繁出现 Top-1 类别变化，或者预测置信度波动较大，说明该样本可能位于学生模型的分类边界附近。

系统将此类样本标记为不稳定样本，并调用教师模型进行二次判断。

综合以上条件，只要出现低置信度、Top-1/Top-2 接近、姿态质量较差或预测不稳定中的任意一种情况，即可触发教师模型。这样可以将大模型计算资源集中用于真正困难的样本，而无需对所有视频进行重复推理。

7.3 学生模型与教师模型结果融合

教师模型被触发后，系统同时获得学生模型和教师模型的预测结果。协同决策模块根据两侧结果的一致性和可靠程度形成最终判断，而不是简单规定教师模型直接覆盖学生模型。

当 Student 与 Teacher 预测为同一类别时，说明两种模型基于不同信息来源得到了相同判断，此时系统直接接受该类别作为最终自动识别结果，并保留双方的预测概率和推理信息。

当两个模型预测类别不同，但 Student 本身表现出明显不确定性，例如 Top-1 置信度较低、Top-1 与 Top-2 差距很小，而 Teacher 给出了较为明确的判断时，可以优先采用 Teacher 的结果。

例如：

代码片段 (plain text)		
Student		
playful_push		0.43
conflict_push		0.40
Teacher		
playful_push		0.12
conflict_push		0.81

此时 Student 在两个类别之间存在明显混淆，而 Teacher 对 t_{push} 的判断更加明确，因此系统采用教师模型结果。

需要注意的是，Teacher 并不具有无条件覆盖 Student 的权限。如果教师模型本身置信度较低、认为证据不足，或者输出存在异常，则不能强制修改学生模型结果。

因此，正常情况下的融合逻辑可以概括为：

代码片段 (plain text)

Student 与 Teacher 一致

↓

直接确认结果

Student 明显不确定，Teacher 判断明确

↓

优先采用 Teacher

双方均较可靠但类别不同

↓

进入异常与人工审核流程

这种方式避免使用复杂的固定权重融合，同时保留了学生模型的运动识别能力和教师模型的语义纠错能力。

7.4 冲突、异常与人工审核机制

当 Student 与 Teacher 无法形成可靠的自动结果，或者系统运行过程中出现模型、输入数据等异常时，当前样本进入异常处理流程。对于仍无法通过自动机制解决的样本，最终进入人工审核队列。

7.4.1 模型高置信冲突

如果 Student 与 Teacher 给出的类别不同，并且双方均具有较高置信度，则认为当前样本存在明显模型冲突。

例如：

代码片段 (plain text)

Student:

playful_chase 0.82

Teacher:

<code>conflict_chase</code>	0.79
-----------------------------	------

这类情况不采用简单概率平均，也不规定某一个模型固定具有更高优先级，而是直接将样本标记为高风险冲突样本。

当前工程可将 Student 与 Teacher 置信度均达到 0.70 以上且类别不同作为高置信冲突条件，该阈值后续可根据实际验证结果调整。

7.4.2 教师模型异常

由于 Teacher 属于生成式模型，其结果在进入协同决策之前需要进行结构化校验，主要检查：

- 输出类别是否属于六个合法类别；
- 概率是否处于合法范围；
- 概率分布是否完整；
- 最终类别是否与最高概率类别一致；
- 必要字段是否完整。

如果输出不符合要求，可以进行有限次数重新解析或重新推理。若仍然无法得到合法结果，则本次教师结果不参与自动决策。

此外，如果 Teacher 因 GPU 资源不足、模型服务异常、显存不足或推理失败等原因无法运行，而当前样本原本已经因为 Student 不确定而触发 Teacher，则不能重新直接采用原本不可靠的 Student 结果，而应将样本保留到人工审核流程。

7.4.3 输入数据异常

对于视频损坏、无法检测到有效人物、大量关键点缺失或人物跟踪严重失败等情况，系统首先判断剩余信息是否仍然能够支持可靠推理。

如果骨架数据质量较差，则优先结合仍然可靠的关键点、轨迹和结构化语义信息进行判断；当有效信息不足时，不再调用 Teacher 强制分类，而是进入异常或人工审核流程。

如果有效信息已经不足以支持可靠分类，则不强制产生六分类标签，而是将样本标记为异常数据，例如 `damaged` 或 `t_of_scope`，避免无效数据产生错误标签。

7.4.4 人工审核触发

当自动协同机制无法安全形成最终结果时，系统将样本送入人工审核队列。主要包括以下情况：

1. Student 与 Teacher 均具有较高置信度，但预测类别不同；
2. Teacher 明确表示当前证据不足，需要人工确认；
3. 困难样本已经触发 Teacher，但 Teacher 当前不可用；
4. Teacher 多次输出异常，无法获得合法结构化结果；
5. 输入视频或姿态数据严重异常，无法可靠分类；
6. Student 多次推理持续出现类别变化或明显不稳定。

人工审核界面应展示原始视频、骨架结果、Student Top-K 预测、Teacher 预测结果、教师判断依据以及触发审核的具体原因，使审核人员能够结合原始证据完成最终判断。

人工确认后的标签具有最高决策优先级：

$$y_F = y_H$$

其中 y_H 表示人工确认的最终类别。

系统同时保存人工标签、审核原因、备注以及 Student 和 Teacher 的推理快照，保证整个决策过程可追溯。

经过人工确认的困难样本还可以在后续数据筛选后重新加入训练数据，使学生模型逐步学习这些容易产生混淆的决策边界样本，为后续模型迭代提供数据基础。


第 8 章 模型压缩与知识蒸馏

8.1 设计目标

当前 Campus6 行为识别模型采用 FP32 精度进行推理，模型性能较好，但文件体积较大。为降低部署成本，本阶段采用 QAT INT8 量化 + Logits 知识蒸馏的方案，在显著压缩模型大小的同时，尽可能保持原始模型的分类能力。

系统保留原始 FP32 Campus6 模型作为 Teacher，将经过 QAT 量化训练的模型作为 Student。Teacher 输出六维分类 logits，Student 在学习真实标签的同时学习 Teacher 的类别分布，从而补偿量化带来的精度损失。

最终流程如图所示：



8.2 模型压缩方案选择

本项目同时测试了量化与剪枝及其组合方案，结果如下：

模型	Test Accuracy	ALL Accuracy	模型部署大小
M0 FP32	88.68%	96.65%	16.59MB
M1 QAT INT8	83.02%	95.81%	4.35 MB
M1I4KD: INT4	58.49%	57.82%	2.80 MB
M1I4KD: INT4 + Logits KD	54.72%	56.42%	2.80 MB
M1KD QAT INT8 + Logits KD	86.79%	96.37%	4.35 MB
M2 剪枝 + INT8	56.60%	78.77%	3.41 MB
M3 剪枝 + INT8 + Logits KD	60.38%	72.07%	3.41 MB

剪枝虽然可以将模型进一步压缩至 3.41 MB，但准确率下降较大，即使加入知识蒸馏也无法恢复到可接受水平。因此最终不采用剪枝，而选择 QAT INT8 + Logits KD。该方案能够将模型从 16.30 MB 压缩至 5.31 MB，同时保持较高的识别准确率。

8.3 INT8 量化设计

原始模型采用 FP32 参数，而 INT8 使用 8 bit 表示权重和激活，因此可以显著减少模型存储空间。


本系统采用 QAT (Quantization Aware Training, 量化感知训练)。训练过程中通过 Fake Quantization 模拟 INT8 的舍入和截断误差，使模型提前适应量化后的数值变化。

量化过程表示为：

$$x_q = \text{clamp} \left(\text{round} \left(\frac{x}{s} \right) + z \right)$$

其中 ss 为量化尺度，zz 为零点。

整体流程为：



实验中，模型文件大小由 40.53 MB 降低至 5.31 MB，说明量化能够显著降低部署模型的存储占用。

8.4 Logits 知识蒸馏设计

INT8 量化会引入数值误差，因此量化后的模型可能出现一定程度的精度下降。为恢复这部分能力，本系统使用原始 FP32 模型作为 Teacher，QAT INT8 模型作为 Student。

对于同一个输入样本 xx ：

$$z_T = f_T(x)$$

$$z_S = f_S(x)$$

其中：

- z_T 为 FP32 Teacher 输出的六维原始 logits；
- z_S 为量化 Student 输出的六维 logits。

Teacher 在蒸馏过程中保持冻结，仅负责提供分类知识。Student 同时学习真实标签和 Teacher logits。

相比单独使用 One-hot 标签，Teacher logits 还包含不同类别之间的相对关系，因此可以帮助量化后的 Student 更好地保持原始模型的分类边界。

8.5 蒸馏损失设计

首先使用 Temperature TT 对 Teacher 和 Student 的 logits 进行平滑：

$$p_T = \text{softmax}\left(\frac{z_T}{T}\right)$$

$$p_S = \text{softmax}\left(\frac{z_S}{T}\right)$$

随后通过 KL 散度计算知识蒸馏损失：

$$L_{KD} = T^2 D_{KL}(p_T \| p_S)$$

同时保留真实标签对应的交叉熵损失：

$$L_{CE} = \text{CrossEntropy}(z_S, y)$$

最终损失函数为：

$$\lambda L_{KD}$$


其中 L_{CE} 保证 Student 学习真实标签， L_{KD} 约束 Student 的输出分布接近原始 FP32 Teacher。

实验初始设置为：

$$T = 4, \quad \lambda = 1.0$$

8.6 QAT 与知识蒸馏联合训练

训练阶段同时加载 FP32 Teacher 和 Fake-INT8 Student：



同时：



Teacher 全程冻结，不参与参数更新。Student 在适应 INT8 量化误差的同时学习原始 FP32 模型的分类能力。

训练完成后，将 Student 正式转换为 INT8 模型。Teacher 仅在训练阶段使用，因此不会增加最终部署模型的大小和推理开销。

最终，普通 QAT INT8 模型的 Test Accuracy 为 83.02%，加入 Logits 蒸馏后提高至 86.79%，模型大小仍保持 5.31 MB。因此最终采用 QAT INT8 + Logits Knowledge Distillation 作为 Campus6 模型的轻量化方案。

注：由于 int8 模型置信度过高，所以我们采用温度 =5 来对它输出的 logits 进行软化

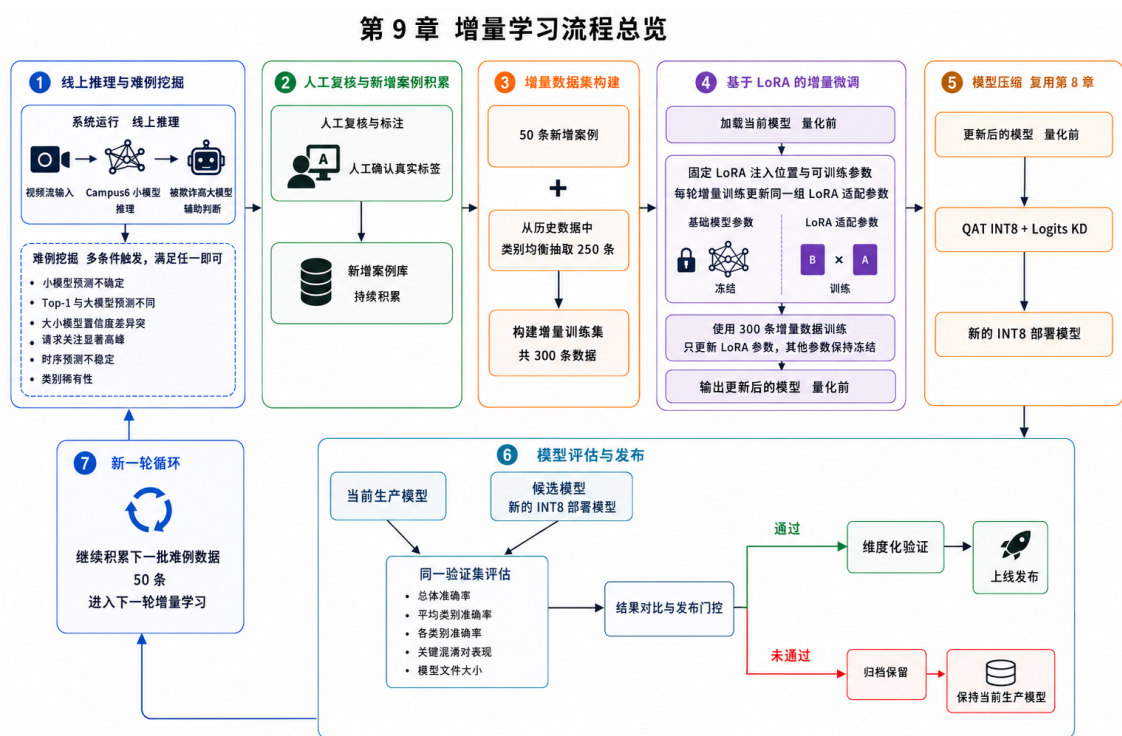
第 9 章 增量学习机制

9.1 增量学习总体设计

校园行为识别系统在实际运行过程中会不断产生新的行为样本，其中包括新的场景数据、模型误识别样本、低置信度样本以及大小模型判断存在冲突的样本。如果模型始终使用初始训练数据进行训练，其识别能力将难以随着实际部署环境的变化持续提升。因此，本系统设计增量学习机制，使 Campus6 行为识别模型能够利用运行过程中持续积累的数据进行周期性更新。

考虑到 Campus6 当前仅包含六类校园行为，整体数据规模较小，本系统不采用持续在线更新模型参数的方式，而采用样本积累—难例挖掘—增量数据集构建—模型微调—模型压缩—评估发布的周期式增量学习流程。

整体流程如下：



注意，系统始终保留 FP32 Campus6 模型作为可持续训练的基础模型，因此，增量学习不会直接在已经量化的 INT8 模型上继续训练，而是首先更新 FP32 模型，再根据更新后的 FP32 模型重新生成对应的轻量化 INT8 部署模型。

这种方式将“模型能力更新”和“模型部署压缩”两个过程分离，使增量学习过

程中始终能够在完整精度模型上进行参数优化，同时保证最终部署模型仍然满足系统对模型体积和推理效率的要求。

9.2 难例挖掘与高价值样本发现

并非所有新增数据都具有相同的训练价值。在系统实际运行过程中，大量正常行走、正常跑步等高置信度样本通常已经能够被 Student 模型正确识别，重复使用这些简单样本进行训练对模型性能提升有限。

因此，本系统重点从线上推理数据中自动发现当前模型识别能力较弱的困难样本 (Hard Samples)，将有限的人工审核和增量训练资源集中到更具有信息价值的数据上。

当前项目已经实现独立的难例挖掘模块。难例挖掘模块能够读取 Student 模型预测结果，并在存在 Teacher 推理结果时进一步结合 Teacher 信息计算样本难度。当前代码中的难例评分主要考虑以下因素：

1. 小模型预测不确定当 Campus6 小模型 Top-1 与 Top-2 类别预测概率过于接近时，说明模型无法明确区分两个类别，将其标记为难例。
2. 大小模型预测不同当 Campus6 小模型与视觉语言大模型对同一样本给出不同类别判断时，将其标记为难例。
3. 大小模型高置信度冲突当大小模型分别以较高置信度判断为不同类别时，例如：

$$l_{push} \leftrightarrow conflict_{push}$$

$$l_{chase} \leftrightarrow conflict_{chase}$$

将其作为重点难例并优先进入人工复核。

4. 类别稀有当某一类别当前样本数量明显少于其他类别时，该类别的新样本作为难例处理，以缓解类别不平衡。

注：在 4 个因素之前，还有一个决定是否调用大模型的门控，也就是当小模型 Top-1 置信度高于 0.3 时，不调用大模型，不进入难例判断

一个样本可以同时满足多个难例条件，经过人工确认标签后的难例进入后续训练数据。

9.3 增量数据集构建与采样策略

系统将经过人工确认的难例作为新增训练数据持续积累。当新增难例累计达到 50 条时，启动一次增量训练。

每次训练时，从历史训练集中抽取 250 条样本，与 50 条新增难例共同组成固定

规模的增量训练集：

$$D_{inc} = D_{hard}^{50} \cup D_{history}^{250}$$

因此：

$$|D_{inc}| = 300$$

其中：

- 50 条新增难例用于强化模型对近期误识别样本和易混淆行为的学习；
- 250 条历史样本用于保持模型已有的六分类识别能力，降低增量训练过程中的灾难性遗忘风险。

历史样本采用类别均衡采样，尽量保证 Campus6 六个行为类别均有样本参与训练，避免新增难例集中在少数类别时造成模型分类能力偏移。

因此，每轮增量训练统一采用：

50 条新增难例 + 250 条类别均衡历史样本

构成 300 条训练数据。

9.4 基于 LoRA 的增量微调

每当累计 50 条新增难例后，系统将其与从历史数据中抽取的 250 条样本组成 300 条增量训练集，并采用 LoRA (Low-Rank Adaptation) 对当前 Campus6 模型进行增量微调。

LoRA 冻结基础模型的大部分参数，仅通过低秩矩阵学习少量增量参数：

$$\Delta W = BA$$

模型更新表示为：

$$W' = W_0 + BA$$

LoRA 在模型中的注入位置在首次配置后保持固定。后续每轮增量微调均更新同一组 LoRA 适配参数，不改变 LoRA 的作用层，也不解冻基础模型的其他参数。因此，每轮增量学习的可训练参数集合保持一致，只改变输入的增量训练数据。

相比全参数微调，LoRA 只更新少量且固定的参数，可以降低单次增量训练的计算成本，并减少不同批次新增数据对模型主体参数的大范围扰动。

同时，300 条训练数据中保留 250 条类别均衡的历史样本，使模型在重点学习最新 50 条难例的同时继续保持原有六分类知识，从而降低灾难性遗忘风险。

增量微调针对量化前的 Campus6 模型进行，微调完成后得到更新后的模型，再交由第 8 章的模型压缩模块生成新的 INT8 部署模型。

9.5 增量训练触发与任务调度

系统以累计 50 条新增难例作为一次增量学习的触发条件。

训练任务启动前，需要检查当前训练环境，包括：

- 新增难例数量是否达到要求；
- 当前 FP32 模型 checkpoint 是否有效；
- GPU 资源是否可用；
- 是否已有其他模型训练任务正在执行。

只有满足全部条件后才启动本轮增量训练。训练成功后，已参与训练的 50 条难例被记录，系统继续累计下一批新增难例。

9.6 模型评估、更新与回滚


新生成的 INT8 模型作为 Candidate Model，与当前部署的 Baseline Model 进行对比评估。

主要评估：

- 六分类总体准确率；
- 平均类别准确率；
- 各类别准确率；

Candidate 模型只有在整体性能满足要求且不存在明显性能退化时才能替换当前生产模型。

如果评估通过：



如果评估未通过，则保留当前生产模型，并归档本轮 Candidate。

第 10 章 Web 可视化与交互演示

10.1 系统首页 / 总览页：



10.2 行为识别结果页：

有样本选择栏、骨架流视频、六分类 Logits、人工标注栏、大模型分析（如果同时是“待人工审核难例”）



10.3 大模型伪标签和人工审核页

10.4 增量学习和模型迭代页

10.5 模型管理页

10.6 系统设置页





第 11 章 项目代码结构与关键接口

代码片段 (plain text)

DAHUA/	
—— src/dahua_cup/	主应用包
—— backend/	FastAPI、任务和审核库
—— visualization/	Web 前端
—— pipeline/	推理、训练和离线工具
—— semantic_teacher/	Qwen 教师、伪标签和蒸馏
—— feature_extraction/	骨架特征摘要
—— evaluation/	评估与审计
—— configs/campus/	Campus6 配置
—— demo/	本地演示（非生产入口）
—— scripts/	启动脚本
—— third_party/ProtoGCN/	固定的上游模型代码与配置
—— tests/	单元与集成测试
—— docs/	设计、部署与验收文档
—— models/	本地模型；仅跟踪 MANIFEST
—— runtime/	运行数据、审核库、产物和日志（不提交）

Github 仓库: <https://github.com/Usernamezju/DAHUA>

第 12 章 预训练与微调数据集

数据集构建与划分。模型首先在 Kinetics-400 上进行预训练。Kinetics-400 是大规模人体动作识别数据集，包含 400 类动作，每类至少 400 段、时长约 10 秒的视频，原始视频主要采集自 YouTube，覆盖人与物体交互、人与人交互等多种真实场景。项目采用其二维骨架数据训练 ProtoGCN，并以 Kinetics-400 预训练的骨干网络参数作为六分类任务的初始化。

针对校园场景，我们进一步构建了 Campus6 六分类微调数据集。数据主要整合自 KTH、Kinetics、BEHAVE、CMU Tagging 等公开行为数据集，并补充从 YouTube 等公开视频平台筛选、裁剪和人工整理的相关行为片段。不同来源的视频统一经过姿态估计与骨架格式转换，形成 COCO-17 双人骨架序列，并重新标注为六类：正常行走、正常奔跑、嬉戏追逐、嬉戏推搡、冲突追逐、冲突推搡。最终基线共包含 358 条样本，按源视频分组划分为训练集 252 条、验证集 53 条、测试集 53 条，避免同源片段跨集合造成数据泄漏。数据集划分如下表：

类别	总计	训练集	验证集	测试集
normal_walk	62	44	9	9
normal_run	72	50	11	11
playful_chase	81	57	12	12
playful_push	75	53	11	11
conflict_chase	16	12	2	2
conflict_push	52	36	8	8
合计	358	252	53	53

第 14 章 项目完成情况

本项目围绕校园场景下的六类行为识别任务，构建了“骨架特征提取—时空关系建模—大模型语义推理—伪标签筛选—知识蒸馏—难例挖掘—增量学习—边缘部署”的完整技术链路。项目已完成全部必选功能，并进一步实现了 Web 可视化、人工审核、模型发布与回滚等工程化功能，形成可解释、可进化、轻量化且兼顾隐私保护的行为识别系统。

14.1 功能模块完成情况

模块	项目实现方式	完成情况
时空特征提取	原始视频首先经过 RTMDet 完成人体检测，再利用 RTMPose 提取人体关键点，统一转换为 COCO-17 骨架序列。进一步从连续骨架中计算人员中心位置、运动速度、轨迹变化、姿态覆盖率、双人距离等可量化时空特征，为后续行为识别和语义推理提供结构化输入。	已完成
时空图构建	基于连续骨架轨迹构建 Spatio-Temporal Graph。以场景中的人员作为节点，以人员之间的接近、距离变化、可能接触等关系作为边，并记录关系持续时间、最小距离、运动状态及姿态质量等信息，将原始坐标序列提升为可表达交互关系的时空结构。	已完成

语义映射层	设计结构化语义映射模块，将时空图中的人员状态、轨迹特征、交互关系、时间片段和姿态质量整理为标准化 Semantic Graph，并自动转换为版本化 Prompt。Prompt 中明确限定六类行为标签，并要求大模型仅依据实际测量证据进行判断，禁止臆测攻击意图、恐惧、防御等无法从骨架直接观测的信息。	已完成
大模型推理模块	引入 Qwen3-VL 作为语义 Teacher，对匿名骨架视频及结构化时空语义信息进行多模态推理。模型输出六类行为概率分布、置信度、判断依据、反证信息及是否需要人工审核等结构化结果，实现对传统骨架模型难例的语义补充判断。	已完成
伪标签筛选策略	并非直接采用大模型输出作为训练标签，而是建立多信号质量评分机制，综合大模型多次推理一致性、Teacher 置信度、Student-Teacher 一致性、姿态质量及时序稳定性进行评分。同时针对师生高置信冲突、推搡缺少接触证据、追逐缺少持续相对运动、骨架跟踪异常等情况自动进入人工复核队列，保证伪标签质量。	已完成

知识蒸馏框架	建立 ProtoGCN Teacher-Student 蒸馏框架。最终部署模型采用 Logits Knowledge Distillation，通过真实标签交叉熵与 Teacher 软概率分布的 KL 散度联合训练，使轻量 Student 继承高精度模型的类别分布信息；代码中同时实现了可选择的 Early/Middle/Deep 三阶段特征对齐机制，可进一步进行多层级蒸馏。	已完成
增量学习机制	建立完善的数据闭环。系统根据 Student 熵值、Top-1/Top-2 间隔、时序不稳定性、师生分歧、低频类别等因素进行难例挖掘；难例经过 Qwen 辅助判断和人工审核后进入增量数据池。增量训练采用“新增难例 + 类别均衡历史样本”的 Replay 策略，并设置候选模型评测、发布门控和模型回滚机制，避免新增数据导致旧类别灾难性遗忘。	已完成
可视化展示	实现基于 FastAPI 和 Web 前端的行为识别可视化系统，可展示六类行为预测结果、Top-K 概率、Skeleton 视频、姿态质量、难例队列、大模型推理依据、人工审核记录、模型状态及增量训练状态等。同时提供模型发布、审核和系统运行状态相关接口，实现从算法到系统的完整演示。	已完成（可选项已实现）

14.2 综合技术要求完成情况

类别	项目完成情况	满足情况
可解释性	系统不仅输出最终行为类别，还输出结构化推理依据。大模型结果包含行为概率分布、置信度、evidence、counter_evidence、reason 及 needs_review 等字段；其依据直接来自轨迹速度、人员距离、接近过程、姿态覆盖率等可测量信息。例如，可通过“双人持续接近且距离显著缩短”“轨迹存在持续跟随关系”等证据解释追逐类判断，从而避免传统分类模型仅给出标签而无法说明原因的问题。	满足
可进化性	构建“Student 预测 → 难例发现 → 大模型辅助判断 → 人工审核 → 伪标签/真实标签沉淀 → 增量训练 → 候选模型评测 → 重新部署”的闭环机制。系统可持续收集真实场景中的低置信和高价值样本，并利用历史样本 Replay 维持原有能力，使模型能够随着新数据持续优化。系统还设计了每轮“50 条新难例 + 250 条类别均衡历史样本”的 300 条增量训练策略。	满足

轻量化	在高精度 FP32 ProtoGCN 基础上采用 QAT 量化感知训练和 Logits 知识蒸馏得到 M1KD INT8 学生模型。最终模型文件约 5.4 MiB，远低于题目要求的 50 MB，同时在 358 条 Campus6 基线数据上取得 345/358 的整体正确结果，实现模型精度与边缘部署体积之间的平衡。	显著满足
鲁棒性	输入侧采用人体骨架而非 RGB 外观作为主要识别信息，从机制上降低服装颜色、背景和光照变化对行为分类的干扰；训练阶段采用时间均匀采样、左右翻转等数据增强，并统一转换至 COCO-17 骨架空间。系统同时监测姿态覆盖率、跟踪失败和时序稳定性，对遮挡严重或姿态质量较低的样本不进行盲目高置信判断，而是自动进入人工复核流程，从而提升复杂场景下的可靠性。	满足
隐私保护	系统采用 Pose-only 隐私策略。原始视频仅在边缘侧短暂用于人体检测与姿态估计，随后转换为匿名 COCO-17 骨架数据；Web 端仅展示 Skeleton 视频及结构化语义信息，不向浏览器传输原始 RGB 视频。配置中关闭 RGB 回退，并设置原始视频保留时间为 0，从数据链路上减少人脸、服装、身份及场景隐私泄露风险。	满足

代码规范	项目采用标准 Python src 工程结构，将后端服务、模型推理、训练流水线、语义 Teacher、特征提取、评估、配置、可视化和测试进行模块化拆分；同时提供 README、依赖文件、启动脚本、模型 MANIFEST、设计及验收文档，并配套单元测试和集成测试。训练、推理、评估、难例分析等功能均提供独立命令行入口，便于复现、部署和后续维护。	满足
------	---	----

14.3 项目整体完成度总结

综上，本项目已完成题目要求的全部核心模块，并在基本功能之外实现了较完整的工程化闭环。系统以前端 RTMDet/RTMPose 实现隐私友好的骨架感知，以 ProtoGCN 作为高效的六分类 Student 模型，以 Qwen3-VL 作为仅在难例条件下触发的语义 Teacher，通过时空图和结构化 Prompt 提升模型的可解释能力；再结合多信号伪标签筛选、人工复核、知识蒸馏、难例挖掘和增量学习，使模型具备持续进化能力。最终通过 QAT INT8 与 Logits 蒸馏将部署模型压缩至约 5.4 MiB，并配套 Web 可视化、审核追踪、模型发布和回滚机制，实现了从算法设计、模型训练到实际部署和持续迭代的完整校园行为识别方案。

参考资料

参考文献

- [1] W. Kay, J. Carreira, K. Simonyan, B. Zhang, C. Hillier, S. Vijayanarasimhan, F. Viola, T. Green, T. Back, P. Natsev, *et al.*, “The Kinetics human action video dataset,” *arXiv preprint arXiv:1705.06950*, 2017.
- [2] C. Schuldt, I. Laptev, and B. Caputo, “Recognizing human actions: A local SVM approach,” in *Proceedings of the 17th International Conference on Pattern Recognition*, pp. 32–36, 2004.
- [3] S. Blunsden and R. B. Fisher, “The BEHAVE video dataset: Ground truthed video for multi-person behavior classification,” *Annals of the BMVA*, vol. 2010, no. 4, pp. 1–12, 2010.
- [4] C. Lyu, W. Zhang, H. Huang, Y. Zhou, Y. Wang, Y. Liu, S. Zhang, and K. Chen, “RTMDet: An empirical study of designing real-time object detectors,” *arXiv preprint arXiv:2212.07784*, 2022.
- [5] T. Jiang, P. Lu, L. Zhang, N. Ma, R. Han, C. Lyu, Y. Li, and K. Chen, “RTM-Pose: Real-time multi-person pose estimation based on MMPose,” *arXiv preprint arXiv:2303.07399*, 2023.
- [6] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *Computer Vision – ECCV 2014*, pp. 740–755, 2014.
- [7] W. Xiang, C. Li, Y. Zhou, B. Wang, and L. Zhang, “Generative action description prompts for skeleton-based action recognition,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 10276–10287, 2023.
- [8] S. Yan, Y. Xiong, and D. Lin, “Spatial temporal graph convolutional networks for skeleton-based action recognition,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018.
- [9] H. Liu, Y. Liu, M. Ren, H. Wang, Y. Wang, and Z. Sun, “Revealing key details to see differences: A novel prototypical perspective for skeleton-based action recognition,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

-
- [10] S. Bai *et al.*, “Qwen3-VL technical report,” *arXiv preprint arXiv:2511.21631*, 2025.
 - [11] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” *arXiv preprint arXiv:1503.02531*, 2015.
 - [12] S. Han, J. Pool, J. Tran, and W. Dally, “Learning both weights and connections for efficient neural network,” in *International Conference on Learning Representations*, 2016.
 - [13] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko, “Quantization and training of neural networks for efficient integer-arithmetic-only inference,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 2704–2713, 2018.