



浙江大学

ZHEJIANG UNIVERSITY

校园行为识别系统
系统设计文档

大华杯项目设计文档

2026 年 8 月 31 日

目录

第 1 章 文档概述	1
1.1 编写目的	1
1.2 项目背景	1
1.3 项目目标	1
第 2 章 系统需求分析	2
2.1 功能需求	2
2.1.1 时空特征提取	2
2.1.2 时空图构建	2
2.1.3 语义映射	2
2.1.4 大模型推理	2
2.1.5 伪标签筛选	2
2.1.6 知识蒸馏	3
2.1.7 增量学习	3
2.1.8 可视化展示	3
2.2 非功能需求	3
2.2.1 可解释性	3
2.2.2 可进化性	3
2.2.3 轻量化	4
2.2.4 鲁棒性	4
2.2.5 隐私保护	4
2.2.6 代码规范	4
第 3 章 系统总体设计	5
3.1 总体架构图	5
3.2 系统模块划分	5
第 4 章 数据处理与骨架特征构建	7

4.1	数据输入	7
4.2	视频帧处理	8
4.2.1	帧采样	8
4.2.2	图像预处理	8
4.3	人体检测与多人姿态估计	9
4.3.1	RTMDet-S 人体检测	9
4.3.2	RTMPose-S 姿态估计	11
4.3.3	COCO17 骨架关键点	12
4.4	人体关联与跟踪	13
4.4.1	IoU 匹配	13
4.4.2	中心距离	13
4.4.3	短时遮挡处理	14
4.4.4	双人轨迹选择	15
4.5	坐标归一化	15
4.6	时序质量控制与关键点处理	16
4.6.1	关键点置信度过滤	16
4.6.2	人体缺失处理	16
4.6.3	时序平滑与插值	17
4.7	输出格式	17
第 5 章	语义增强的轻量级骨架行为识别模型设计	19
5.1	模型训练总体思路	19
5.2	阶段一：基于 Kinetics-400 的骨架动作预训练	20
5.2.1	骨架输入与时空图构建	20
5.3	ProtoGCN 主干：从关节运动到细粒度拓扑特征	21
5.3.1	GCN Block 与多尺度时间建模	21
5.4	MTE：增强样本相关的细粒度运动拓扑	22
5.5	PRN：基于运动原型重构高层关节关系	23
5.6	CSCL：增强原型重构结果的类别判别能力	25
5.7	阶段一训练结果：获得通用人体动作先验	26
5.8	阶段二：Campus6 六分类全参数微调	27
5.9	GAP：利用动作自然语言描述辅助 Campus6 微调	28

5.9.1	Campus6 身体部位级动作语义 Prompt	29
5.10	文本描述的语义编码	30
5.11	身体部位骨架特征提取	31
5.12	骨架—文本语义对齐	31
5.13	GAP 身体部位语义损失	33
5.14	Campus6 微调阶段联合损失	33
第 6 章	大模型语义理解设计	35
6.1	多源输入	36
6.1.1	结构化语义信息	36
6.1.2	骨架视频流	36
6.1.3	学生模型 Top-KK 预测	37
6.2	提示词构建	38
6.2.1	教师角色定义	38
6.2.2	六分类类别约束	39
6.2.3	学生预测使用约束	39
6.2.4	事实约束与幻觉抑制	40
6.2.5	当前 Prompt 模板	41
6.3	大模型推理	42
6.3.1	结构化交互语义理解	43
6.3.2	骨架运动时序理解	43
6.3.3	学生预测参考与语义修正	43
6.4	结构化输出	44
6.4.1	伪标签	45
6.4.2	类别概率分布	45
6.4.3	置信度	46
6.4.4	语义解释	46
第 7 章	大小模型协同决策机制	48
7.1	协同架构	48
7.2	大模型触发策略	48
7.2.1	预测置信度较低	49

7.2.2	Top-1 与 Top-2 过于接近	49
7.2.3	姿态数据质量较差	49
7.2.4	预测结果不稳定	50
7.3	学生模型与教师模型结果融合	50
7.4	冲突、异常与人工审核机制	51
7.4.1	模型高置信冲突	51
7.4.2	教师模型异常	52
7.4.3	输入数据异常	52
7.4.4	人工审核触发	52
第 8 章	模型压缩与知识蒸馏	54
8.1	设计目标	54
8.2	模型压缩方案选择	54
8.3	INT8 量化设计	55
8.4	Logits 知识蒸馏设计	56
8.5	蒸馏损失设计	56
8.6	QAT 与知识蒸馏联合训练	57
第 9 章	增量学习机制	59
9.1	增量学习总体设计	59
9.2	难例挖掘与高价值样本发现	60
9.3	增量数据集构建与采样策略	60
9.4	基于 LoRA 的增量微调	61
9.5	增量训练触发与任务调度	62
9.6	模型评估、更新与回滚	62
第 10 章	Web 可视化与交互演示	64
10.1	系统首页 / 总览页:	64
10.2	行为识别结果页:	64
10.3	大模型伪标签和人工审核页	64
10.4	增量学习和模型迭代页	64
10.5	模型管理页	64

10.6 系统设置页	64
第 11 章 项目代码结构与关键接口	67
第 12 章 预训练与微调数据集	68
第 14 章 项目完成情况	69
14.1 功能模块完成情况	69
14.2 综合技术要求完成情况	72
14.3 项目整体完成度总结	74

第 1 章 文档概述

1.1 编写目的

本文档用于描述系统的总体架构、功能模块、核心算法、数据流程、接口设计及部署方案，为系统开发、测试和验收提供依据。

1.2 项目背景

随着智慧校园建设不断推进，校园公共区域的视频行为分析逐渐成为安全管理的重要手段。现有算法多依赖速度、距离和轨迹等表层时空特征，对“嬉戏追逐”“冲突推搡”等相似行为的语义区分能力有限，容易产生误报。同时，传统模型面对新型行为时迭代成本较高。因此，本项目拟构建大小模型协同的校园行为语义理解框架，在提升识别准确性的同时兼顾模型轻量化与持续进化能力。

1.3 项目目标

1. 实现六类校园行为细粒度识别；
2. 提升嬉戏行为与冲突行为的区分能力；
3. 建立大小模型协同机制；
4. 建立数据—大模型—小模型自进化闭环；
5. 实现边缘端轻量化部署；
6. 保护隐私，不随意上传视频

第 2 章 系统需求分析

2.1 功能需求

根据赛题基本功能要求，系统应具备时空特征提取、时空图构建、语义映射、大模型推理、伪标签筛选、知识蒸馏、增量学习以及结果可视化等功能。

2.1.1 时空特征提取

系统应能够从输入的校园行为视频或结构化人体关键点数据中提取与行为识别相关的时空信息，包括人体关键点、运动轨迹、运动速度及人体交互状态等，为后续行为建模提供基础数据。

2.1.2 时空图构建

系统应能够根据人体关键点及其时间序列关系构建 Spatio-Temporal Graph，将人体关键点表示为图节点，并通过空间连接关系和时间关联关系构建图边，实现人体行为的结构化表示。

2.1.3 语义映射

系统应能够将骨架运动特征、模型预测结果及相关行为信息转换为大模型能够理解的结构化语义描述或文本 Prompt，为后续大模型行为推理提供输入。

2.1.4 大模型推理

系统应支持调用大模型对行为样本进行进一步语义分析，重点处理小模型难以准确区分的低置信度、高混淆行为。

大模型应能够根据输入的行为信息输出行为类别、预测置信度及对应的判断结果，并为后续伪标签生成和知识迁移提供依据。

2.1.5 伪标签筛选

系统应能够对大模型产生的预测结果进行质量筛选，根据预测置信度等指标选择可靠的高质量样本。

对于置信度不足、模型结果存在冲突或难以确定的样本，应进入人工复核队列，避免低质量伪标签直接参与模型训练。

2.1.6 知识蒸馏

系统应建立 Teacher-Student 知识迁移框架，将大模型产生的高质量行为判断知识迁移至轻量级行为识别模型。

知识蒸馏可采用预测分布、软标签等信息进行知识传递，使轻量模型逐步学习大模型对复杂行为的判断能力。

2.1.7 增量学习

系统应支持将新增数据、困难样本以及经过筛选的伪标签样本加入训练数据集，对轻量模型进行进一步训练和更新。

通过难例挖掘、数据注入及模型微调，使模型能够随着新数据的不断积累持续提升行为识别能力。

2.1.8 可视化展示

系统可提供行为识别结果的可视化界面，用于展示输入视频、人体骨架、预测类别、预测置信度及相关推理结果，方便用户查看系统识别过程及最终结果。

2.2 非功能需求

2.2.1 可解释性

系统应能够输出行为识别结果对应的推理依据，使用户能够了解系统进行行为判断的主要依据。

对于调用大模型分析的样本，应能够输出自然语言形式的语义判断依据；对于仅由轻量模型完成推理的样本，应保证其预测类别和置信度等信息可追溯。

2.2.2 可进化性

系统应设计完整的数据闭环机制，使新增数据和困难样本能够经过大模型分析、伪标签筛选和人工复核后重新进入训练流程。

通过知识蒸馏和增量学习不断更新轻量模型，实现系统随数据积累持续优化。

2.2.3 轻量化

系统应满足边缘部署要求，最终部署模型大小应不超过 50 MB。

在保证行为识别性能的前提下，应通过轻量化模型设计及模型量化等方式降低模型存储空间和计算开销。

2.2.4 鲁棒性

系统应对实际校园场景中的复杂环境具有一定适应能力，包括：

- 人体部分遮挡；
- 光照条件变化；
- 摄像机视角变化；
- 多人交互场景；
- 部分人体关键点缺失或检测误差。

2.2.5 隐私保护

系统设计应尽量减少对原始视频及人脸信息的依赖。

在行为识别阶段优先采用人体姿态及骨架数据作为模型输入，减少原始人脸和视频信息在后续处理、存储及传输过程中的暴露风险。


2.2.6 代码规范

系统代码应具有清晰的模块划分和目录结构，关键算法及核心流程应提供必要注释。

项目应提供 README 文档，说明环境配置、模型运行、训练测试及系统启动方式，保证系统具有良好的可维护性和可复现性。

第 3 章 系统总体设计

3.1 总体架构图



3.2 系统模块划分


模块	功能
数据输入模块	视频读取与预处理
骨架提取模块	多人关键点检测
小模型识别模块	六类行为分类
语义映射模块	将骨架行为转换为语义信息
大模型推理模块	细粒度行为语义判断
协同决策模块	综合大小模型结果
蒸馏模块	大模型知识迁移

增量学习模块	新数据加入和模型升级
可视化模块	展示识别结果

第 4 章 数据处理与骨架特征构建

本系统采用基于人体骨架的行为识别方案。原始视频首先经过视频解码和时序采样，再使用经过 INT8 量化的 RTMDet-S INT8 和 RTMPose-S 模型分别进行人体检测和关键点提取。针对校园交互行为中常见的双人场景，系统进一步通过时序轨迹关联保持人物身份的一致性，并最终形成统一的 COCO17 Skeleton Sequence，供后续轻量级行为识别模型使用。

整体数据预处理流程（RGB 流）



4.1 数据输入

系统输入为校园场景视频：

$$\mathcal{V} = \{I_0, I_1, \dots, I_{N-1}\}$$

其中， I_i 表示第 i 帧图像， N 表示视频总帧数，原始视频帧率记为 f_s ，图像宽、高分别为 WW 和 HH 。

系统支持 MP4、AVI 等常见视频格式。视频读取阶段主要检查视频是否可以正常打开、是否存在可解码帧，以及 FPS、分辨率等基本信息是否有效。

当视频无法提供有效帧率时，可采用默认帧率：

$$f_s = 30 \text{ FPS}$$

以保证后续时序处理正常进行。

4.2 视频帧处理

4.2.1 帧采样

为降低姿态估计计算开销，同时尽可能保留完整动作过程，系统对原始视频进行时序采样。

设最大采样帧数为 $T_{\max}$ 。当：

$$N \leq T_{\max}$$

时，保留全部有效帧；当：

$$N > T_{\max}$$

时，在整个视频范围内进行均匀采样。

第 k 个采样帧位置为：

$$i_k = \text{round} \left(\frac{k(N-1)}{T_{\max}-1} \right), \quad k = 0, 1, \dots, T_{\max}-1$$

这种方法能够使采样帧覆盖动作的开始、发展和结束阶段，避免仅截取视频局部片段。

系统同时支持帧间隔参数 ss ，仅处理满足：

$$i \bmod s = 0$$

的帧。实时推理场景下通常设置：

$$s = 1$$

即逐帧执行姿态估计。

4.2.2 图像预处理

采样得到的第 t 帧表示为：

$$I_t \in \mathbb{R}^{H \times W \times 3}$$

图像直接送入人体检测与 RTMPose 推理流水线。模型所需的尺寸调整、归一化和 Tensor 转换由姿态估计推理框架统一完成。

4.3 人体检测与多人姿态估计

本系统采用 RTMDet-S + RTMPose-S 组成轻量级 Top-down 人体姿态估计流水线。

其中，RTMDet-S 负责在视频帧中定位人体，RTMPose-S 负责在检测到的人体区域中进一步预测人体关键点。

整体过程可表示为：

$$I_t \xrightarrow{\text{RTMDet-S}} B_t^m \xrightarrow{\text{RTMPose-S}} P_t^m$$

其中：

- I_t : 第 t 帧图像；
- B_t^m : 第 t 帧中第 m 个人的人体检测框；
- P_t^m : 该人体对应的 COCO17 骨架关键点。

两个模型均采用 INT8 量化，以降低边缘侧推理的模型存储空间和计算开销。

4.3.1 RTMDet-S 人体检测

对于采样得到的第 t 帧图像：

$$I_t \in \mathbb{R}^{H \times W \times 3}$$

首先使用 RTMDet-S 完成人体检测。

RTMDet-S 输出当前图像中的候选人体边界框集合：

$$D_t = \{B_t^1, B_t^2, \dots, B_t^K\}$$

其中，第 m 个检测结果表示为：